

Estimación No Paramétrica de la Densidad

Ana M. Bianco & Paula M. Spano

Introducción al Aprendizaje Estadístico

Estimadores de núcleos: Selección de ventana

En el gráfico anterior se muestra que la elección de la ventana es crucial.

- Una ventana h pequeña dará un estimador muy rugoso, con muchos picos y difícil de interpretar
- una ventana h grande sobreesuaviza al estimador de la densidad y enmascara estructuras de los datos.

Sesgo y Varianza de $\hat{f}(x)$

Comprobemos en el caso del estimador de Parzen que para que todo funcione bien deben pasar dos cosas:

- $h \longrightarrow 0$
- $nh \longrightarrow \infty$

$$\hat{f}(x) = \frac{1}{2hn} \sum_{i=1}^n \mathcal{I}_{(x-h, x+h)}(X_i)$$

Sesgo y Varianza de $\hat{f}(x)$

$$\hat{f}(x) = \frac{1}{2hn} \sum_{i=1}^n \mathcal{I}_{(x-h, x+h)}(X_i) \quad \text{con} \quad \sum_{i=1}^n \mathcal{I}_{(x-h, x+h)}(X_i) \sim Bi(n, p)$$

donde $p = \mathbb{P}(x - h < X < x + h) = F(x + h) - F(x - h) = p_{x,h}$.

Sesgo y Varianza de $\hat{f}(x)$

$$\hat{f}(x) = \frac{1}{2hn} \sum_{i=1}^n \mathcal{I}_{(x-h, x+h)}(X_i) \quad \text{con} \quad \sum_{i=1}^n \mathcal{I}_{(x-h, x+h)}(X_i) \sim Bi(n, p)$$

donde $p = \mathbb{P}(x - h < X < x + h) = F(x + h) - F(x - h) = p_{x,h}$.
Luego, usando las propiedades de esperanza y varianza:

$$\begin{aligned}\mathbb{E}[\hat{f}(x)] &= \frac{F(x + h) - F(x - h)}{2h}, \\ \mathbb{V}\text{ar}[\hat{f}(x)] &= \frac{F(x + h) - F(x - h)}{4nh^2} - \frac{(F(x + h) - F(x - h))^2}{4nh^2}.\end{aligned}$$

Sesgo y Varianza de $\hat{f}(x)$

$$\hat{f}(x) = \frac{1}{2hn} \sum_{i=1}^n \mathcal{I}_{(x-h, x+h)}(X_i) \quad \text{con} \quad \sum_{i=1}^n \mathcal{I}_{(x-h, x+h)}(X_i) \sim Bi(n, p)$$

donde $p = \mathbb{P}(x - h < X < x + h) = F(x + h) - F(x - h) = p_{x,h}$.
Luego, usando las propiedades de esperanza y varianza:

$$\begin{aligned}\mathbb{E}[\hat{f}(x)] &= \frac{F(x + h) - F(x - h)}{2h}, \\ \mathbb{V}\text{ar}[\hat{f}(x)] &= \frac{F(x + h) - F(x - h)}{4nh^2} - \frac{(F(x + h) - F(x - h))^2}{4nh^2}.\end{aligned}$$

Si

- $h \rightarrow 0$, entonces $\mathbb{E}[\hat{f}(x)] \rightarrow f(x)$ y $\mathbb{V}\text{ar}[\hat{f}(x)] \approx \frac{f(x)}{2nh} - \frac{f(x)^2}{n} \rightarrow \infty$
- $nh \rightarrow \infty$, $n \rightarrow \infty$ $h \rightarrow 0$, entonces sesgo y varianza se reducen.

Sesgo y Varianza de $\hat{f}(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \longrightarrow 0$
- $nh \longrightarrow \infty$

Sesgo y Varianza de $\hat{f}(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \longrightarrow 0$
- $nh \longrightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{B}[\hat{f}(x)] &\approx \frac{h^2}{2} C_1(K) f''(x) \\ \mathbb{V}\text{ar}[\hat{f}(x)] &\approx \frac{1}{nh} C_2(K) f(x)\end{aligned}$$

Sesgo y Varianza de $\hat{f}(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \longrightarrow 0$
- $nh \longrightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{B}[\hat{f}(x)] &\approx \frac{h^2}{2} C_1(K) f''(x) \\ \mathbb{V}\text{ar}[\hat{f}(x)] &\approx \frac{1}{nh} C_2(K) f(x)\end{aligned}$$

- El sesgo es proporcional a $h^2 \Rightarrow$ elijamos h pequeña

Sesgo y Varianza de $\hat{f}(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \longrightarrow 0$
- $nh \longrightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{B}[\hat{f}(x)] &\approx \frac{h^2}{2} C_1(K) f''(x) \\ \mathbb{V}\text{ar}[\hat{f}(x)] &\approx \frac{1}{nh} C_2(K) f(x)\end{aligned}$$

- El sesgo es proporcional a $h^2 \Rightarrow$ elijamos h pequeña
- El sesgo depende de $f''(x)$ que mide la curvatura de f en x

Sesgo y Varianza de $\hat{f}(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \longrightarrow 0$
- $nh \longrightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{E}[\hat{f}(x)] &\approx \frac{h^2}{2} C_1(K) f''(x) \\ \text{Var}[\hat{f}(x)] &\approx \frac{1}{nh} C_2(K) f(x)\end{aligned}$$

- La varianza disminuye a medida que nh crece

Sesgo y Varianza de $\hat{f}(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \longrightarrow 0$
- $nh \longrightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{B}[\hat{f}(x)] &\approx \frac{h^2}{2} C_1(K) f''(x) \\ \mathbb{V}\text{ar}[\hat{f}(x)] &\approx \frac{1}{nh} C_2(K) f(x)\end{aligned}$$

- La varianza disminuye a medida que nh crece
- Para disminuir la varianza necesitamos h o n grandes.

Error Cuadrático Medio de $\hat{f}(x)$

Compromiso Sesgo-Varianza

Tenemos que

$$\text{MSE}[\hat{f}(x)] = \text{Sesgo}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)]$$

Por otro lado:

$$\begin{aligned}\mathbb{E}[\hat{f}(x)] &\approx \frac{h^2}{2} C_1(K) f''(x) \\ \text{Var}[\hat{f}(x)] &\approx \frac{1}{nh} C_2(K) f(x)\end{aligned}$$

Error Cuadrático Medio de $\hat{f}(x)$

Compromiso Sesgo-Varianza

Tenemos que

$$\text{MSE}[\hat{f}(x)] = \text{Sesgo}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)]$$

Por otro lado:

$$\begin{aligned}\mathbb{E}[\hat{f}(x)] &\approx \frac{h^2}{2} C_1(K) f''(x) \\ \text{Var}[\hat{f}(x)] &\approx \frac{1}{nh} C_2(K) f(x)\end{aligned}$$

$$\Rightarrow \text{MSE}[\hat{f}(x)] \approx \frac{h^4}{4} C_1^2(K) (f''(x))^2 + \frac{1}{nh} C_2(K) f(x)$$

Si $h \rightarrow 0$ y $nh \rightarrow \infty$ $\hat{f}(x)$ es un estimador consistente de $f(x)$.

$$\hat{f}_h(x)$$

Por lo que vimos, el efecto de la ventana sobre la estimación de la densidad puede ser crucial, por lo tanto haremos explícita esta dependencia, denotando

$$\hat{f}_h(x)$$

al estimador basado en una ventana h .

Error Cuadrático Medio de $\hat{f}_h(x)$

Compromiso Sesgo-Varianza

Tenemos que

$$\text{MSE}[\hat{f}_h(x)] = \text{Sesgo}^2[\hat{f}_h(x)] + \text{Var}[\hat{f}_h(x)]$$

Por otro lado:

$$\begin{aligned}\mathbb{B}[\hat{f}_h(x)] &\approx \frac{h^2}{2} C_1(K) f''(x) \\ \text{Var}[\hat{f}_h(x)] &\approx \frac{1}{nh} C_2(K) f(x)\end{aligned}$$

$$\Rightarrow \text{MSE}[\hat{f}_h(x)] \approx \frac{h^4}{4} C_1^2(K) (f''(x))^2 + \frac{1}{nh} C_2(K) f(x)$$

Si $h \rightarrow 0$ y $nh \rightarrow \infty$ $\hat{f}_h(x)$ es un **estimador consistente** de $f(x)$.

Error Cuadrático Integrado y Medio Integrado de \hat{f}_h

Como medida global: Error Cuadrático Integrado

$$\text{ISE}[\hat{f}_h] = \int \left(\hat{f}_h(x) - f(x) \right)^2 dx$$

Como medida global: Error Cuadrático Medio Integrado

$$\text{MISE}[\hat{f}_h] = \int \text{MSE}[\hat{f}_h(x)] dx$$

Error Cuadrático Integrado y Medio Integrado de \hat{f}_h

Como medida global: Error Cuadrático Integrado

$$\text{ISE}[\hat{f}_h] = \int \left(\hat{f}_h(x) - f(x) \right)^2 dx$$

Como medida global: Error Cuadrático Medio Integrado

$$\text{MISE}[\hat{f}_h] = \int \text{MSE}[\hat{f}_h(x)] dx$$

Asintóticamente: Error Cuadrático Medio Integrado Asintótico

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} C_1^2(K) \int (f''(x))^2 dx + \frac{1}{nh} C_2(K)$$

Error Cuadrático Integrado y Medio Integrado de \hat{f}_h

Como medida global: Error Cuadrático Integrado

$$\text{ISE}[\hat{f}_h] = \int \left(\hat{f}_h(x) - f(x) \right)^2 dx$$

Como medida global: Error Cuadrático Medio Integrado

$$\text{MISE}[\hat{f}_h] = \int \text{MSE}[\hat{f}_h(x)] dx$$

Asintóticamente: Error Cuadrático Medio Integrado Asintótico

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} C_1^2(K) \int (f''(x))^2 dx + \frac{1}{nh} C_2(K)$$

Si llamamos $\|g\|_2^2 = \int g(t)^2 dt$

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} C_1^2(K) \|f''\|_2^2 + \frac{1}{nh} \|K\|_2^2$$

Error Cuadrático Medio Integrado de \hat{f}_h

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} C_1^2(K) \|f''\|_2^2 + \frac{1}{nh} \|K\|_2^2$$

- Notemos que MISE es una función de la ventana h .
- Derivando a AMISE respecto de h e igualando a 0, obtenemos que el valor de h que minimiza el AMISE es

$$h = \left\{ \frac{\|K\|_2^2}{C_1^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}}$$

Error Cuadrático Medio Integrado de \hat{f}_h

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} C_1^2(K) \|f''\|_2^2 + \frac{1}{nh} \|K\|_2^2$$

- Notemos que MISE es una función de la ventana h .
- Derivando a AMISE respecto de h e igualando a 0, obtenemos que el valor de h que minimiza el AMISE es

$$h = \left\{ \frac{\|K\|_2^2}{C_1^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}} = \text{algo} * \left(\frac{1}{n} \right)^{\frac{1}{5}} \sim n^{-\frac{1}{5}}$$

Selección de h : Regla de Silverman

El $\text{AMISE}[\hat{f}_h(x)]$ se minimiza en

$$h = \left\{ \frac{\|K\|_2^2}{C_1^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}}$$

- Silverman propone reemplazar a $\|f''\|_2^2$ por su valor cuando f es normal:

$$\|f''\|_2^2 = \sigma^{-5} \frac{3}{8\sqrt{\pi}} \approx 0.212 \sigma^{-5}$$

y a σ por un estimador $\hat{\sigma}$

Selección de h : Regla de Silverman

El $\text{AMISE}[\hat{f}_h(x)]$ se minimiza en

$$h = \left\{ \frac{\|K\|_2^2}{C_1^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}}$$

- Silverman propone reemplazar a $\|f''\|_2^2$ por su valor cuando f es normal:

$$\|f''\|_2^2 = \sigma^{-5} \frac{3}{8\sqrt{\pi}} \approx 0.212 \sigma^{-5}$$

y a σ por un estimador $\hat{\sigma}$

$$h_{Sil} = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{\frac{1}{5}} \approx 1.06 \hat{\sigma} n^{-\frac{1}{5}}$$

- Si f es normal, la ventana h_{Sil} es óptima.
- Si f no es normal, h_{Sil} dará una ventana no muy alejada de la óptima cuando la distribución no es muy diferente a la normal.

Selección de h : Regla de Silverman

$$h_{Sil} = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{\frac{1}{5}} \approx 1.06 \hat{\sigma} n^{-\frac{1}{5}}$$

- σ puede estimarse por S (sd(datos) en R).
 - o
- σ puede estimarse por la distancia intercuartil IQR (IQR(datos) en R). Para que coincida con σ bajo la distribución normal debe dividirse por 1.349
- La ventana óptima de acuerdo a la regla de Silverman resulta:

$$h_{Sil} = 1.06 \min \left(S, \frac{IQR}{1.349} \right) n^{-\frac{1}{5}}$$

Volviendo un poco para atrás...

$$\begin{aligned}\text{ISE}[\hat{f}_h(\cdot)] &= \int \left(\hat{f}_h(x) - f(x) \right)^2 \mathrm{d}x \\ &= \int \left(\hat{f}_h(x) \right)^2 \mathrm{d}x - 2 \int \hat{f}_h(x) f(x) \mathrm{d}x \\ &\quad + \int (f(x))^2 \mathrm{d}x.\end{aligned}$$

Como el último término no involucra a h , podemos minimizar

$$A = \int \left(\hat{f}_h(x) \right)^2 \mathrm{d}x - 2 \int \hat{f}_h(x) f(x) \mathrm{d}x$$


Convalidación Cruzada: Splitting the data

Para evitar sobreajuste usamos *Splitting the data*:




(Fuente: James, Witten, Hastie y Tibshirani, 2013)

Convalidación Cruzada: Splitting the data



Convalidación Cruzada

Para evitar sobreajuste usamos *leave-one-out-Cross-Validation*:



Convalidación Cruzada

Bowman (1984) propone estimar a A por

$$\frac{1}{n} \sum_{i=1}^n \int \left(\widehat{f}_h^{(-i)}(x) \right)^2 dx - \frac{2}{n} \sum_{i=1}^n \widehat{f}_h^{(-i)}(x_i) \quad (1)$$

siendo $\widehat{f}_h^{(-i)}(x_i)$ la densidad estimada en el punto x_i sin utilizar al punto x_i :

$$\widehat{f}_h^{(-i)}(x_i) = \frac{1}{(n-1)h} \sum_{j \neq i} K \left(\frac{x_i - x_j}{h} \right)$$

Una versión más simple que se usa en general es:

$$\text{LSCV}(h) = \int \left(\widehat{f}_h(x) \right)^2 dx - \frac{2}{n} \sum_{i=1}^n \widehat{f}_h^{(-i)}(x_i) \quad (2)$$

Convalidación Cruzada

$$\text{LSCV}(h) = \int \left(\hat{f}_h(x) \right)^2 dx - \frac{2}{n} \sum_{i=1}^n \hat{f}_h^{(-i)}(x_i) \quad (3)$$

En general, buscamos el mínimo sobre una grilla h_1, \dots, h_q y luego, eventualmente, se refina.