1. Análisis Exploratorio

Ana M. Bianco & Paula M. Spano

Aprender de los datos:

- La idea es visualizar en forma rápida las principales características del conjunto de datos, analizando posibles relaciones o conexiones entre ciertas variables.

- La relevancia que tiene hacer un análisis gráfico previo es fundamental, pero no siempre es determinante. Si bien una gráfica facilita la visualización de relaciones entre variables, esto no lo confirma.

decía un maestro. . . .

"The simple graph has brought more information to the data analyst's mind than any other device." — John Tukey

Visualizaciones interesantes

- visiten: (https://gisanddata.maps.arcgis.com/apps/opsdashboard/index.html#/bda7594740fd40299423467b48e9ecf6)

- y también (https://www.gapminder.org/tools/#$chart-type=bubbles)

¿Qué buscamos?

Por ejemplo, si tenemos una variable cuantitativa, tratamos de responder a preguntas tales como:

- ¿Son los valores medidos casi todos iguales o son muy diferentes entre sí?
- ¿En qué sentido difieren?
- ¿Las mediciones tienden a concentrarse alrededor de un valor?
- ¿Existe algún patrón o tendencia?
- ¿Constituyen un único grupo? ¿Hay varios grupos?
- ¿Difieren algunos pocos datos notablemente del resto?
- ¿Cómo se relaciona esta variable con otra de nuestro interés tomada en la misma muestra?

Borramos todo y establecemos el directorio de trabajo

```
rm(list=ls())

setwd("C:/Users/Ana/Dropbox/Ana/IntroAE/Clases/01Descriptiva")
#setwd("~/Dropbox/Ciencias_de Datos_Fundamentos/optativa_2020/Clase_1")
```

Datos

Carguemos los datos del Titanic que están en formato CSV (comma separated values)

```
titanico<- read.csv("datos_titanic.csv",header=T)
# Miramos los nombres de las variables
names(titanico)
```

```
##  [1] "PassengerId" "Survived"    "Pclass"      "Name"        "Sex"
##  [6] "Age"         "SibSp"       "Parch"       "Ticket"      "Fare"
## [11] "Cabin"       "Embarked"
```

```
head(titanico)
```

```
##   PassengerId Survived Pclass
## 1           1        0      3
## 2           2        1      1
## 3           3        1      3
## 4           4        1      1
## 5           5        0      3
## 6           6        0      3
##                                                  Name    Sex Age SibSp Parch
## 1                             Braund, Mr. Owen Harris   male  22     1     0
## 2 Cumings, Mrs. John Bradley (Florence Briggs Thayer) female  38     1     0
## 3                              Heikkinen, Miss. Laina female  26     0     0
## 4        Futrelle, Mrs. Jacques Heath (Lily May Peel) female  35     1     0
## 5                            Allen, Mr. William Henry   male  35     0     0
## 6                                    Moran, Mr. James   male  NA     0     0
##             Ticket    Fare Cabin Embarked
## 1        A/5 21171  7.2500              S
## 2         PC 17599 71.2833   C85        C
## 3 STON/O2. 3101282  7.9250              S
## 4           113803 53.1000  C123        S
## 5           373450  8.0500              S
## 6           330877  8.4583              Q
```

```
attach(titanico)
```

Tipos de Variables

Comenzamos a trabajar con las variables en forma individual.

Debemos identificar el tipo de variable con la que vamos a trabajar ya que dependiendo del tipo de variables que tengamos, se determina que análisis o tratamiento a aplicar.

Los tipos de datos pueden ser:

- numérico
- entero
- caracter
- factor
- lógico

Variables Categóricas

```
class(Sex)
```

```
## [1] "character"
```

```
Sex<- as.factor(Sex)
class(Sex)
```

```
## [1] "factor"
```

Es importante que la clase de las variables categóricas sean factor. Sino deberíamos cambiarlo.

El comando *table* aplicado a una variable categórica cuenta la frecuencia de cada categoría

```
table(Sex)
```

```
## Sex
## female   male
##    314    577
```

barplot realiza un diagrama de barras de una variable categórica, para la que hemos calculado antes la tabla de frecuencia con table

Variables Categóricas

```
counts.sexo <- table(Sex)
barplot(counts.sexo,col="blue",density=8)
```

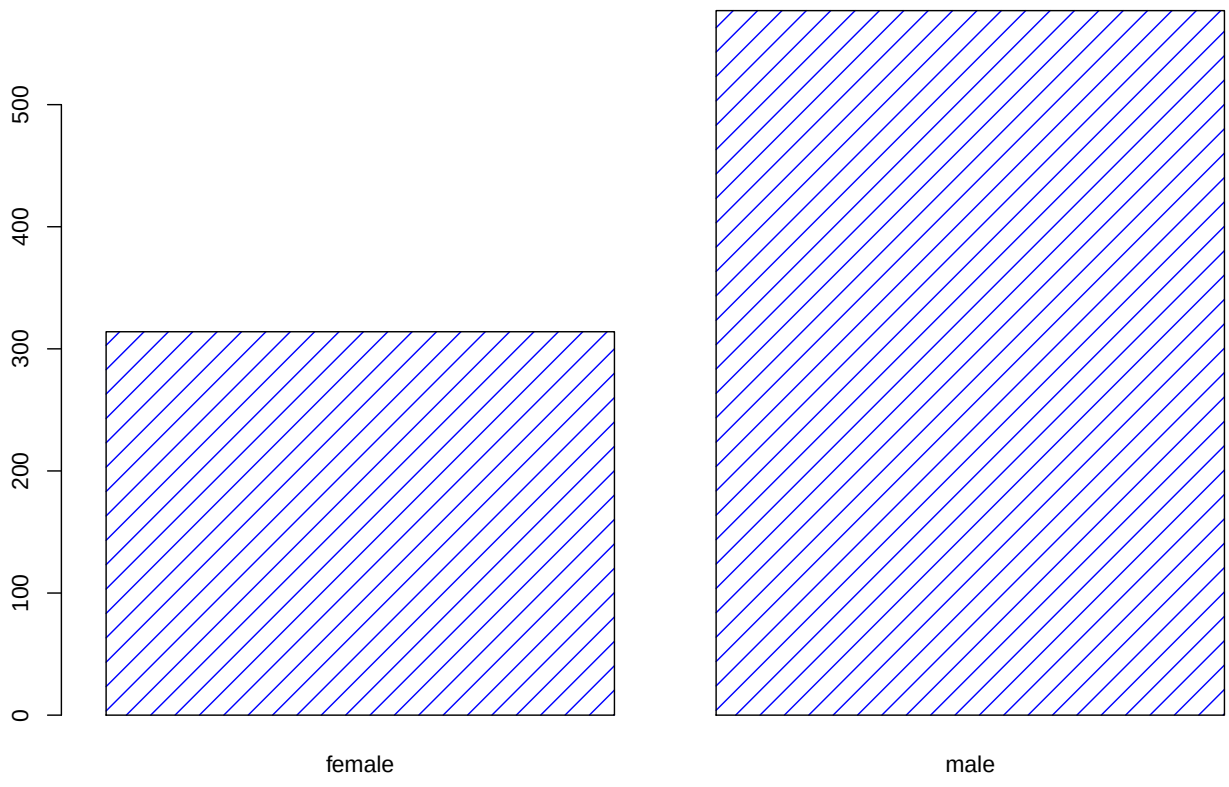

Variables Categóricas

```
Pclass<-as.factor(Pclass)
counts.clase<- table(Pclass)
counts.clase
```

```
## Pclass
##   1   2   3
## 216 184 491
```

```
pie(counts.clase, col=c("blue","green","red"),
    main="Grafico de Torta de Clases")
```

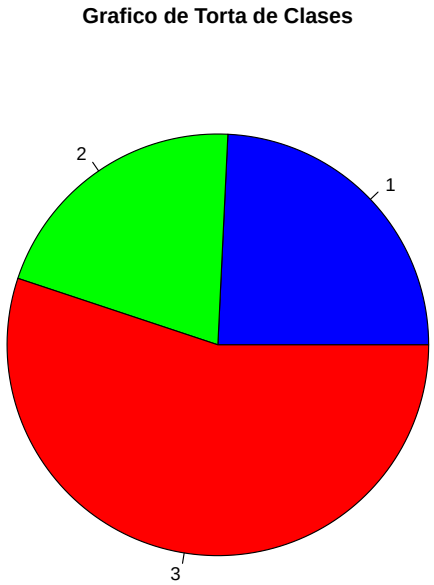

Más de una Variable Categórica

```
counts<- table(Sex,Pclass)
counts
```

```
##          Pclass
## Sex         1   2   3
##   female  94  76 144
##   male   122 108 347
```

```
barplot(counts,col= c( " blue " , "red "),main="Sexo vs. Clase",
        legend = rownames( counts ),args.legend = list(x = "topleft") )
```

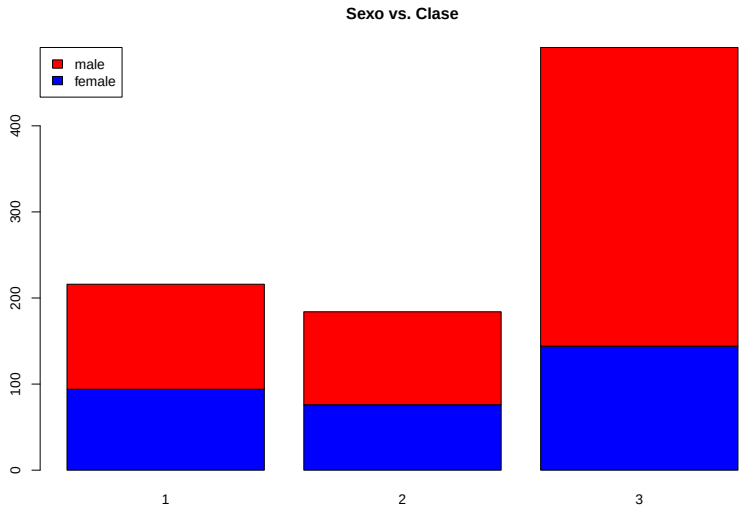

Más de una Variable Categórica

De otro modo

```
counts<- table(Pclass,Sex)
counts
```

```
##        Sex
## Pclass female male
##      1     94  122
##      2     76  108
##      3    144  347
```

```
barplot(counts,col= c( " blue " , "red ","green"),
        legend = rownames( counts ),args.legend = list(x = "topleft") )
```

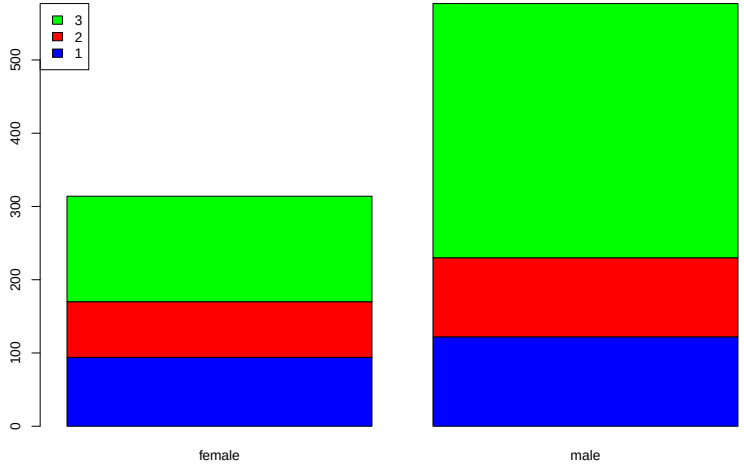

Carguemos los datos de iris

```r
data(iris)

#Inspecciono los primeros y los ultimos casos.
head(iris)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
## 6          5.4         3.9          1.7         0.4  setosa
```

```r
tail(iris)
```

```
##     Sepal.Length Sepal.Width Petal.Length Petal.Width   Species
## 145          6.7         3.3          5.7         2.5 virginica
## 146          6.7         3.0          5.2         2.3 virginica
## 147          6.3         2.5          5.0         1.9 virginica
## 148          6.5         3.0          5.2         2.0 virginica
## 149          6.2         3.4          5.4         2.3 virginica
## 150          5.9         3.0          5.1         1.8 virginica
```

```r
attach(iris)
```

Variables numéricas

Al tratar una variable cuantitativa podríamos calcularle cualquiera de las medidas tales como promedio, desvío standard, etc.

Si la variables tiene observaciones faltantes las funciones no se van a ejecutar hay que decirle a la función que las omita.

```
range(Sepal.Length)
```

```
## [1] 4.3 7.9
```

```
mean(Sepal.Length)
```

```
## [1] 5.843333
```

```
summary(Sepal.Length)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   4.300   5.100   5.800   5.843   6.400   7.900
```

```
mean(Sepal.Length,na.rm=TRUE) #promedio omitiendo missings.
```

```
## [1] 5.843333
```

Medidas de Resumen Comunes

Nombre del comando	Explicación
summary(data)	Resumen estadístico
min(data)	Mínimo
max(data)	Máximo
range(data)	Rango
mean(data)	Media aritmética
median(data)	Mediana
length(data)	Tamaño
sd(data)	Desviación típica
var(data), cov(data)	Varianza
cor(data)	Correlación
sort(data)	Ordenar
table(data)	Tabla de frecuencias absolutas

Medidas de Resumen

Podemos calcular estas funciones también sobre un conjunto de variables

La siguiente matriz contiene las variables Sepal.Length Sepal.Width Petal.Length Petal.Width

```
SUB<-cbind( Sepal.Length, Sepal.Width, Petal.Length, Petal.Width )
# o bien
SUB<-iris[,-5]
```

Por ejemplo, puedo calular la media

```
apply(SUB,2,mean,na.rm=TRUE) ## 2 indica aplicar mean por columna
```

```
## Sepal.Length  Sepal.Width Petal.Length  Petal.Width
##     5.843333     3.057333     3.758000     1.199333
```

Histogramas

El histograma es el más conocido de los gráficos para resumir un conjunto de datos cuantitativos o numéricos.

- Para construir un histograma es necesario previamente construir una tabla de frecuencias: dividimos el rango de los n datos en intervalos o clases, que son excluyentes y exhaustivas.
- Contamos la cantidad de datos en cada intervalo o clase i, es decir la frecuencia, f_i y calculamos la frecuencia relativa: $fr_i = f_i/n$
- Graficamos el histograma en un par de ejes coordenados representando en las abscisas los intervalos y sobre cada uno de ellos un rectángulo cuya área es la frecuencia relativa de dicho intervalo.

Histogramas

```
hist(Sepal.Length)
```

Histogramas

```
par(mfrow=c(1,2))
hist(Sepal.Length,main="Histograma de frecuecias")
hist(Sepal.Length,freq=F,main="Histograma de densidad")
```

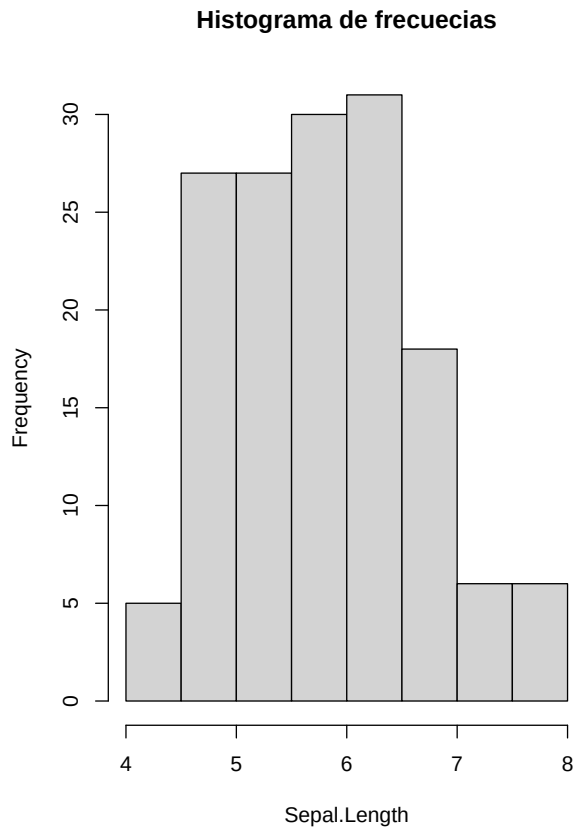

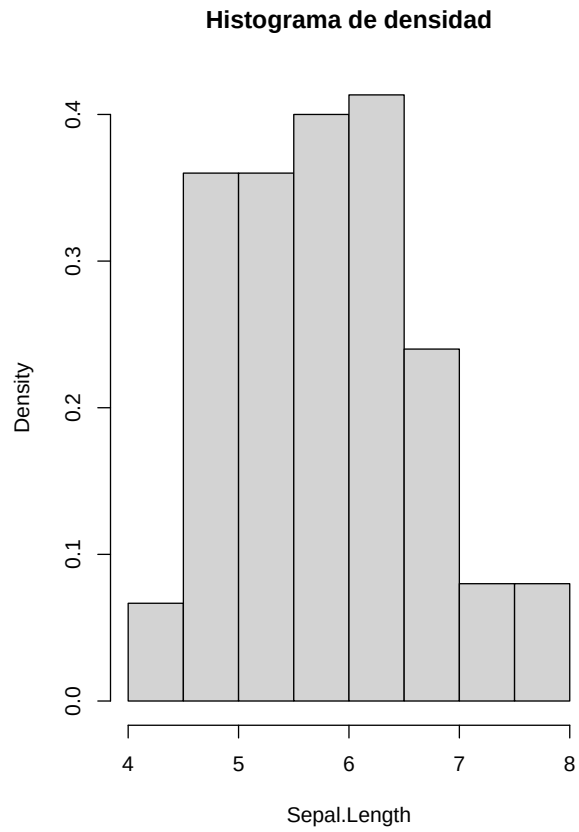


```
par(mfrow=c(1,1))
```

Histogramas

```
par(mfrow=c(1,2)) # Realiza dos gráficos en el mismo cuadro
hist(Sepal.Length,freq=F,col="2",
     breaks = c(3,4.5,5,6.3,6.8,8),xlab="longitud del sepalo",main="")
hist(Sepal.Length,freq=F,col="2",nclass=15,
     xlab="Longitud del sepalo",main="")
```

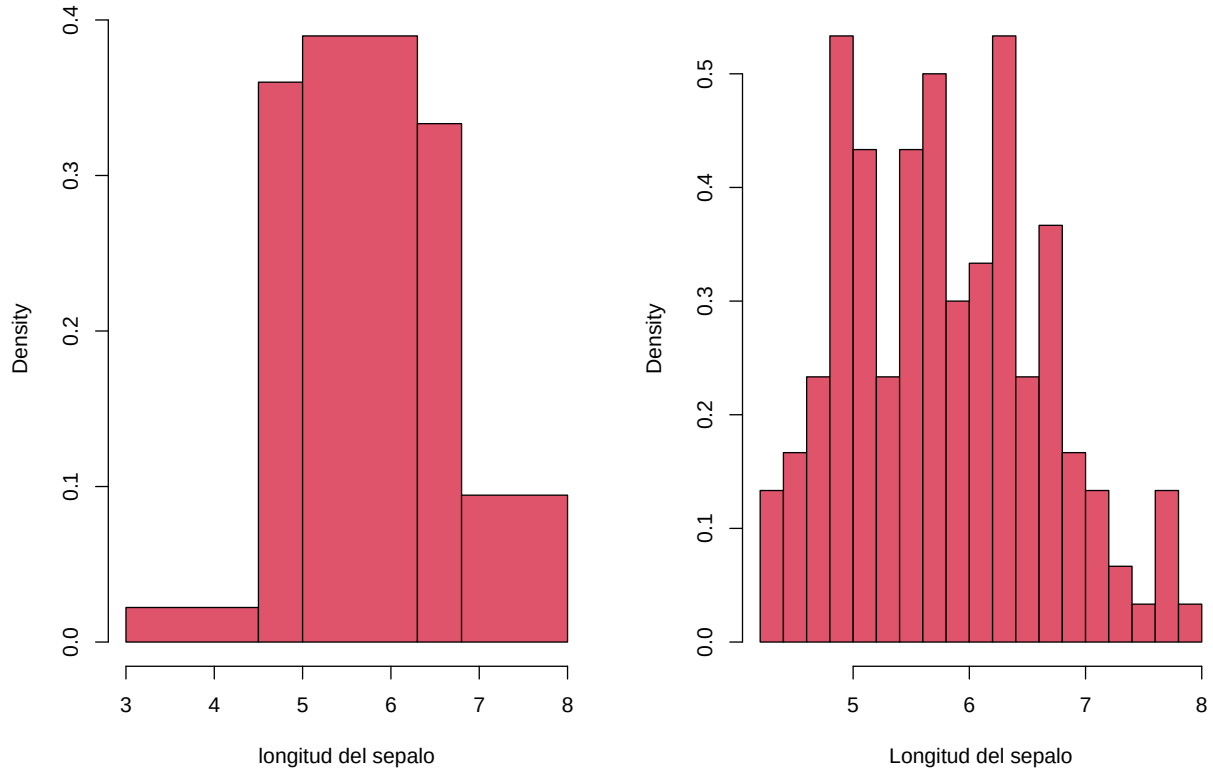

Histogramas

Para guardar los gráficos por líneas de comandos

```
pdf ("histogramas.pdf ")
par(mfrow=c(1,2))
hist(Sepal.Length,freq=F,col="2",breaks = c(3,4.5,5,6.3,6.8,8),
     xlab="longitud del sepalo",main="")
hist(Sepal.Length,freq=F,col="2",nclass=15,
     xlab="Longitud del sepalo",main="")
par(mfrow=c(1,1))
graphics.off()
```

Histogramas

Histograma con la curva de densidad superpuesta

```
media.es<-mean(Sepal.Length)
desvio.es<-sd(Sepal.Length)
grilla<-seq(range(Sepal.Length)[1],
            range(Sepal.Length)[2],length=100)

# Calculamos la densidad normal sobre grilla
funn<-dnorm(grilla,media.es,desvio.es)
```

Histogramas

Histograma con la curva de densidad superpuesta

```
hist(Sepal.Length,nclass=15,freq=F,
     main="Histograma de Densidad de Sepal.Length")
lines(grilla,funn,col="blue",lwd=2)
```

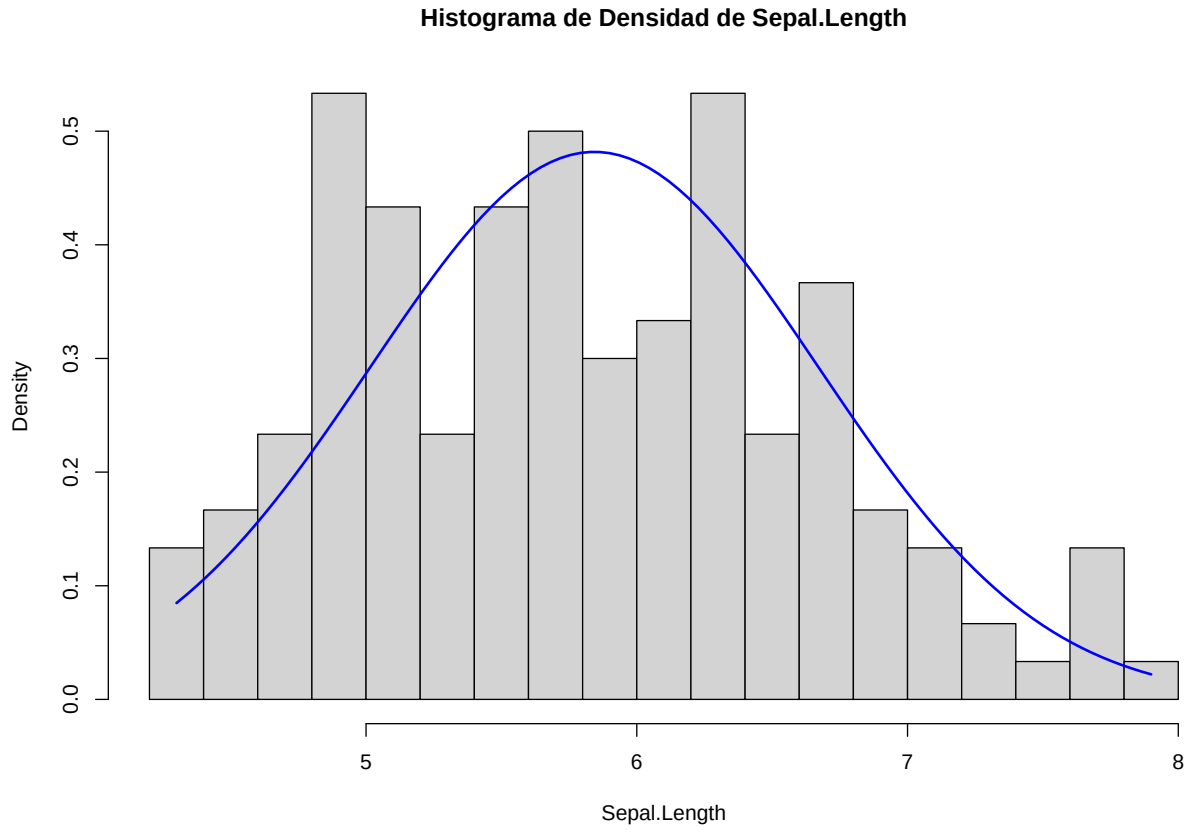

Boxplot

Los cuartiles y la mediana dividen a la muestra en cuatro partes igualmente pobladas: 25% de la muestra en cada una de ellas.

Entre Q1 y Q3 se halla el 50% central de los datos y el rango de estos es IQR=Q3-Q1.

Observemos que porcentaje de datos hay a la izquierda de Q1 a la derecha de Q3 entre Q1 y Q3, Q1 y el máximo entre el mínimo y Q3.

Resultan muy útiles para describir la muestra las siguientes medidas

- Mínimo
- Q1 cuartil inferior
- Q2 mediana
- Q3 cuartil superior
- Máximo

Boxplot

Nombre del comando	Explicación
quantile(data, 0.25)	Cuantil Q1
quantile(data, 0.75)	Cuantil Q3
IQR(data)	Rango intercuartil

Boxplot

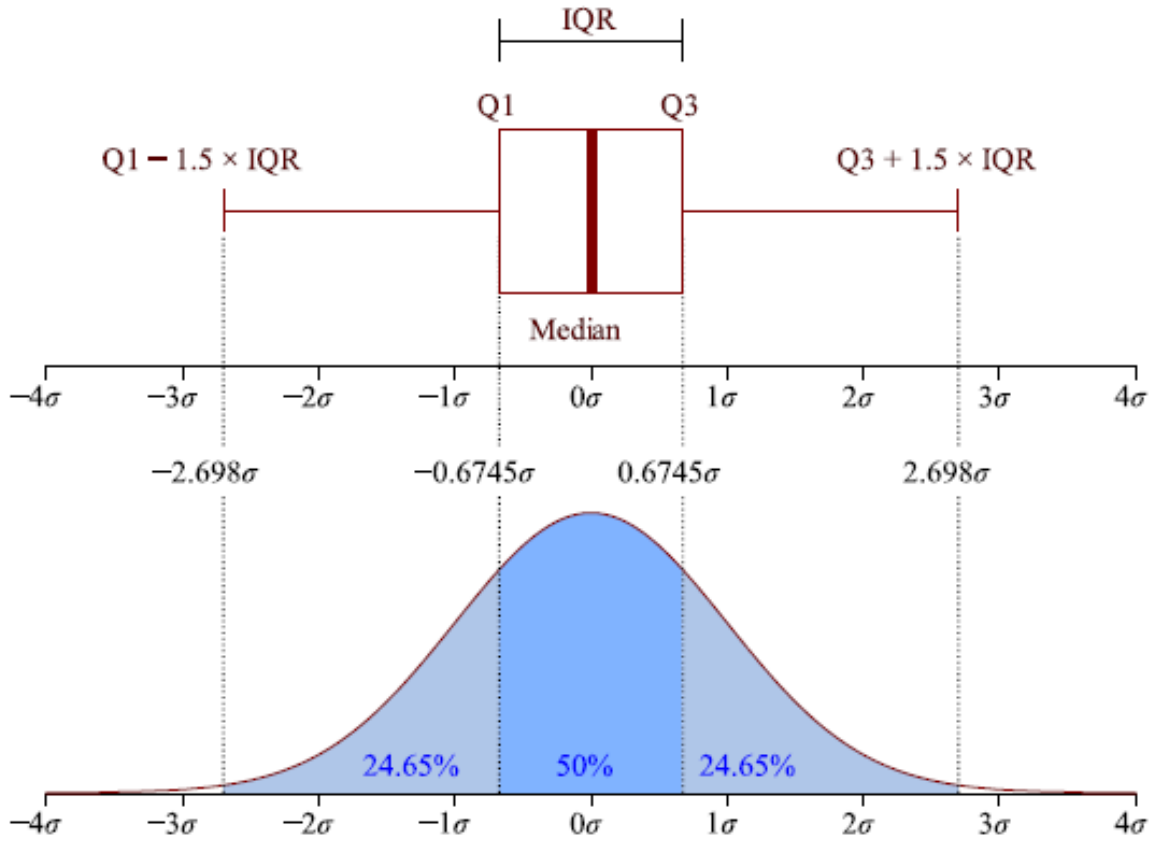

Figure: boxplot

Boxplot

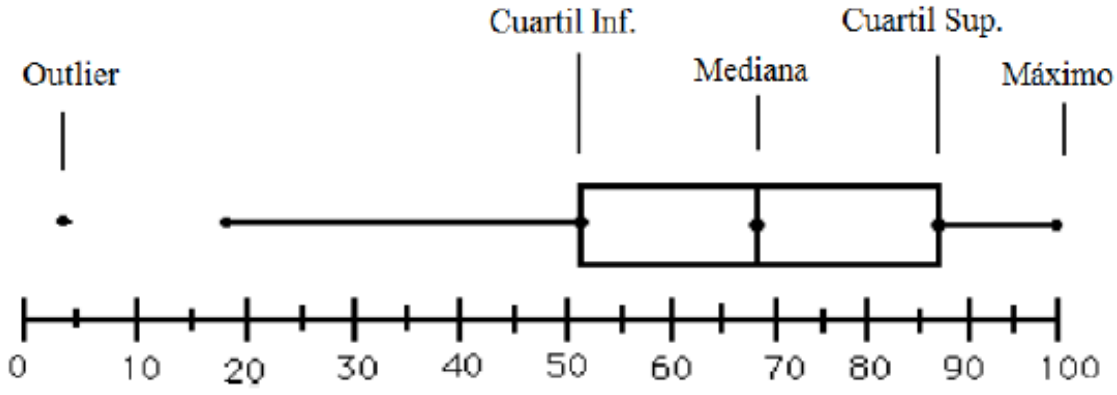

Figure: boxplot

Boxplot

```
boxplot(Sepal.Length)
```

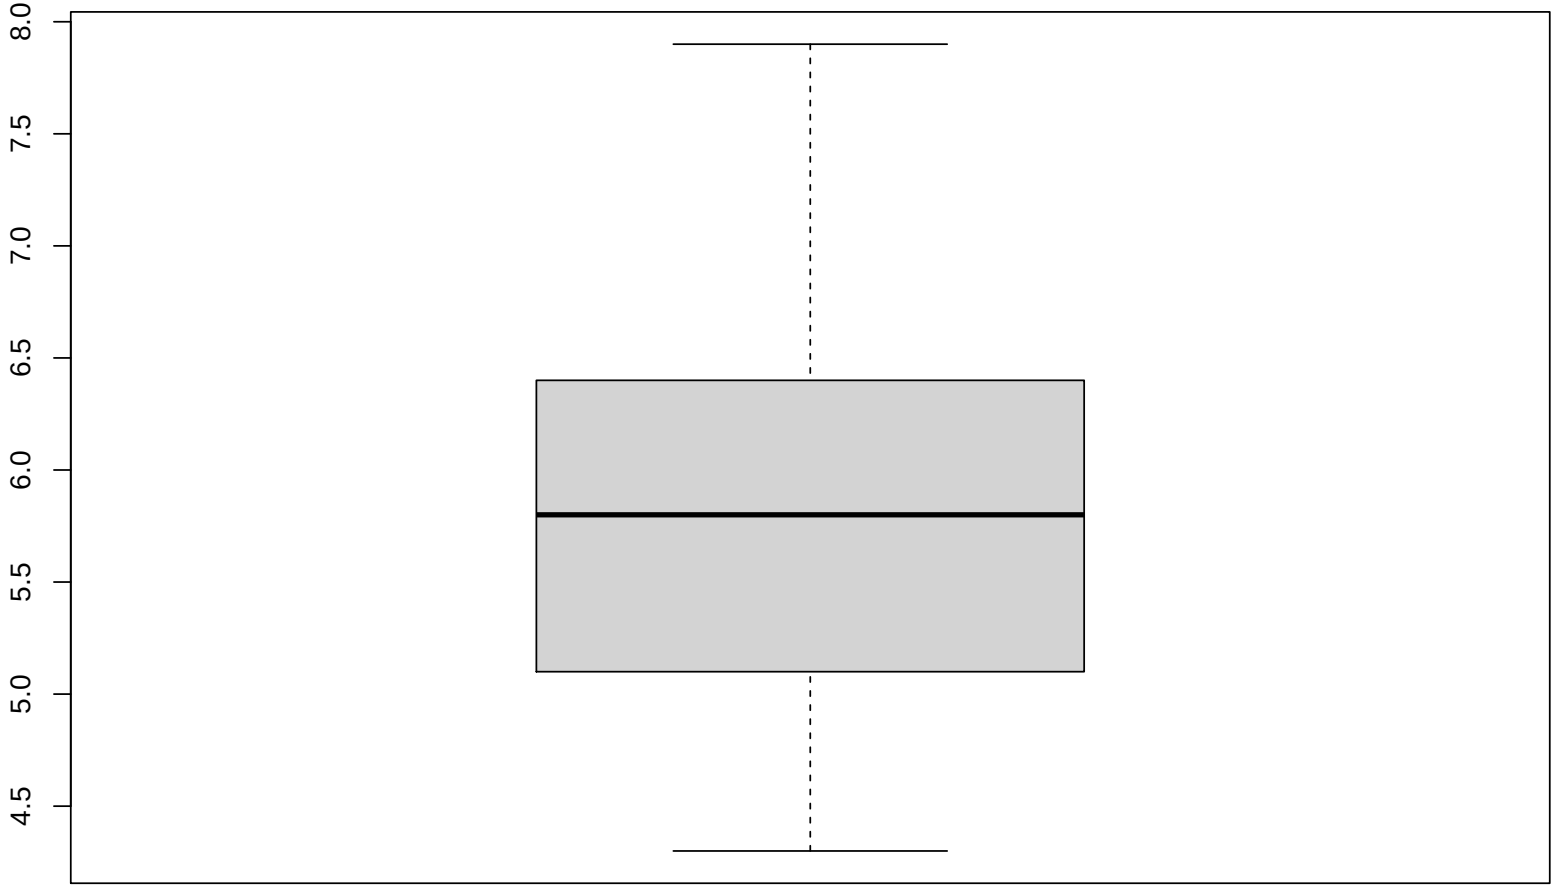

Boxplot

El ~ indica que variable clasifica

```
boxplot(Sepal.Length~Species, xlab="especies",
        main="longitud del sepalo")
```

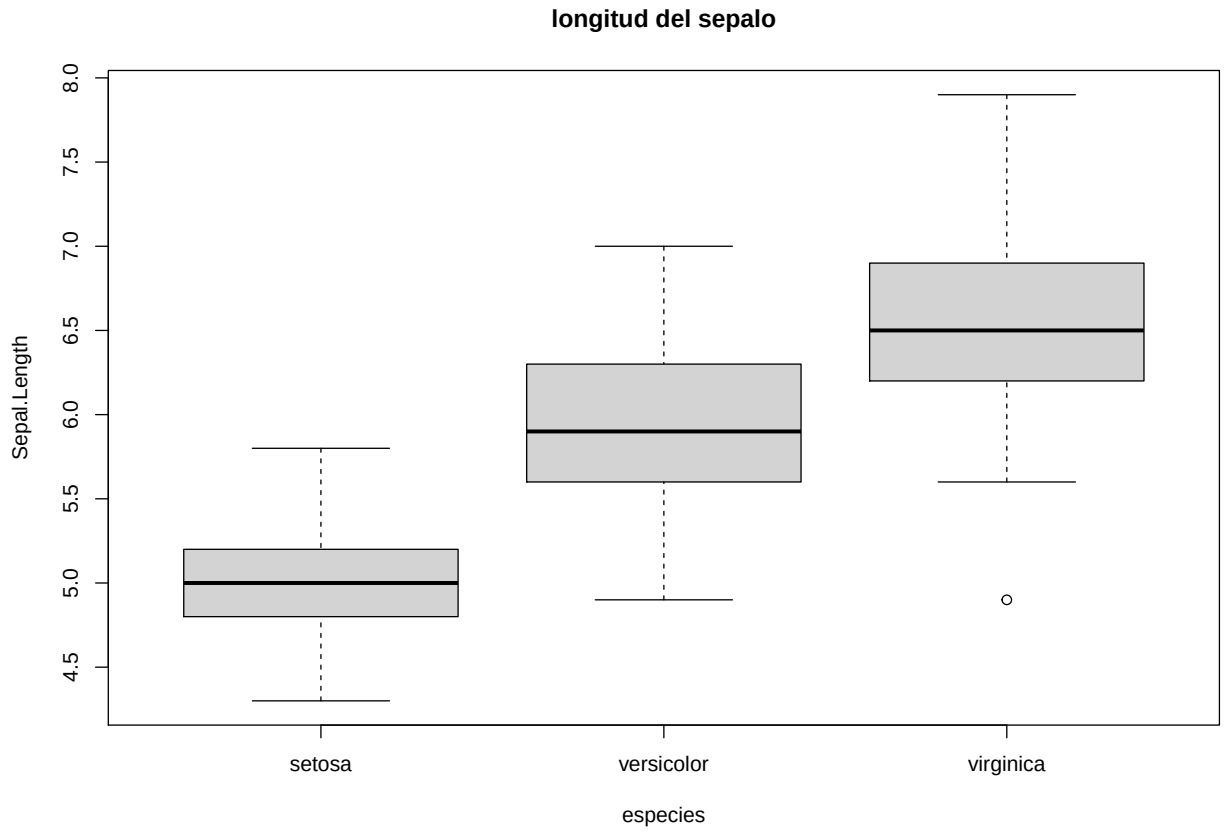

Boxplot

```
boxplot(Sepal.Length,Sepal.Width,
        names=c("longitud","ancho"))
```

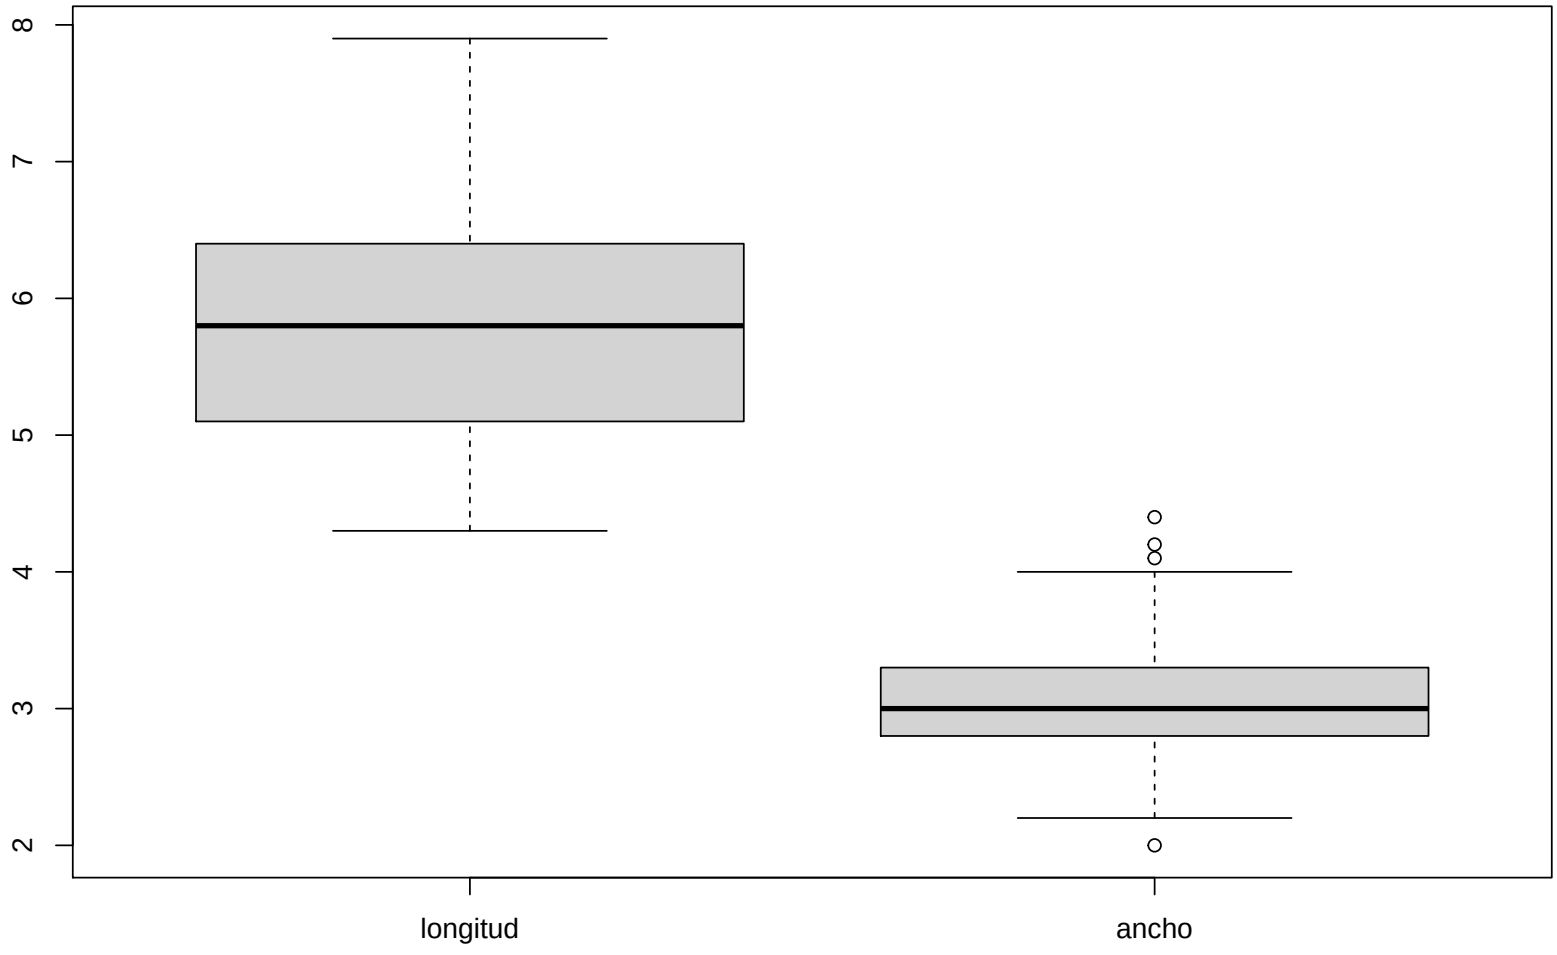

Gráficos para pares de variables

Diagrama de dispersión de Sepal.Length vs. Sepal.Width

```
plot(Sepal.Length,Sepal.Width)
```

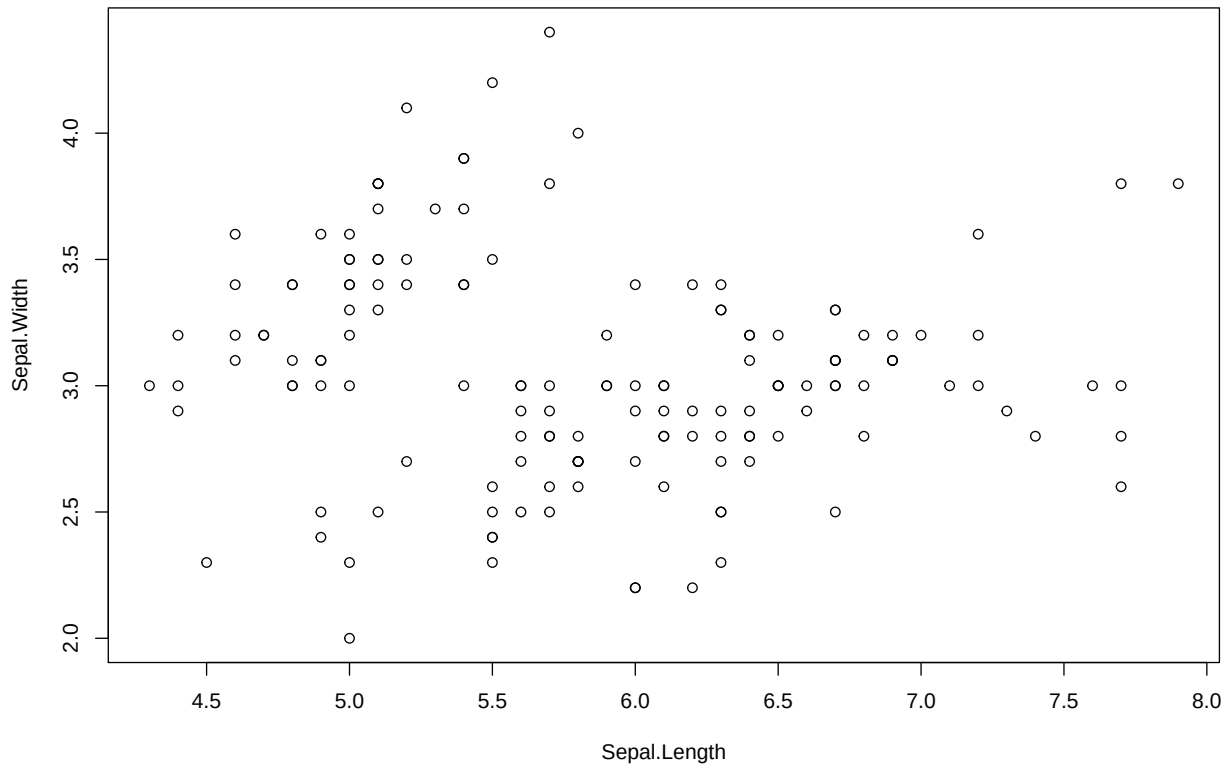

Gráficos para pares de variables

Podemos personalizarlo poniendo labels en cada eje, título y elija un caracter para los puntos.

```
plot(Sepal.Length,Sepal.Width,xlab =" longitud", ylab =" ancho",
     main =" Plot de longitud vs. ancho",pch=16)
```

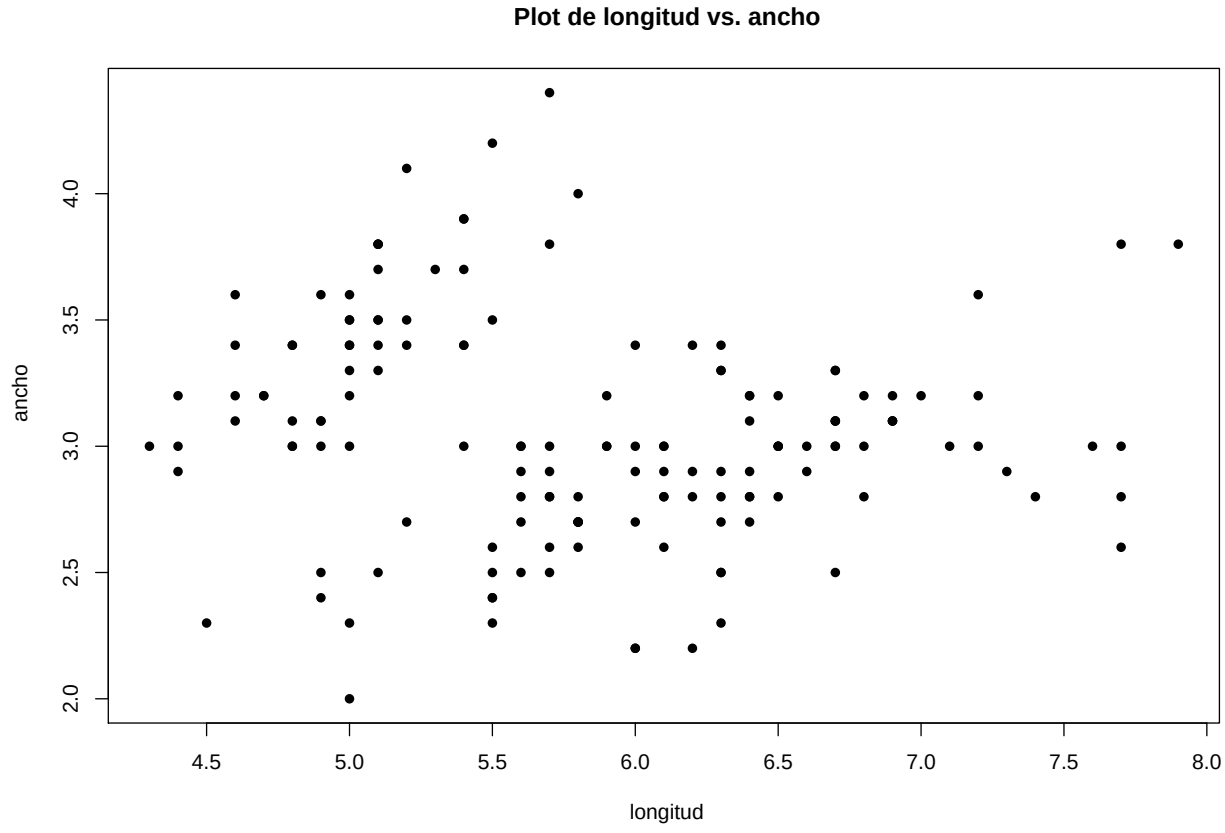

Gráficos para pares de variables

```
plot(Sepal.Length,Sepal.Width,xlab =" longitud", ylab =" ancho",
     main =" Plot de longitud vs. ancho",pch=16,type="n")
#solo graficamos la caja
points(Sepal.Length[Sepal.Length<=6],Sepal.Width[Sepal.Length<=6],
       pch=20,col="magenta")
points(Sepal.Length[Sepal.Length>6],Sepal.Width[Sepal.Length>6],
       pch=20,col="green")
```

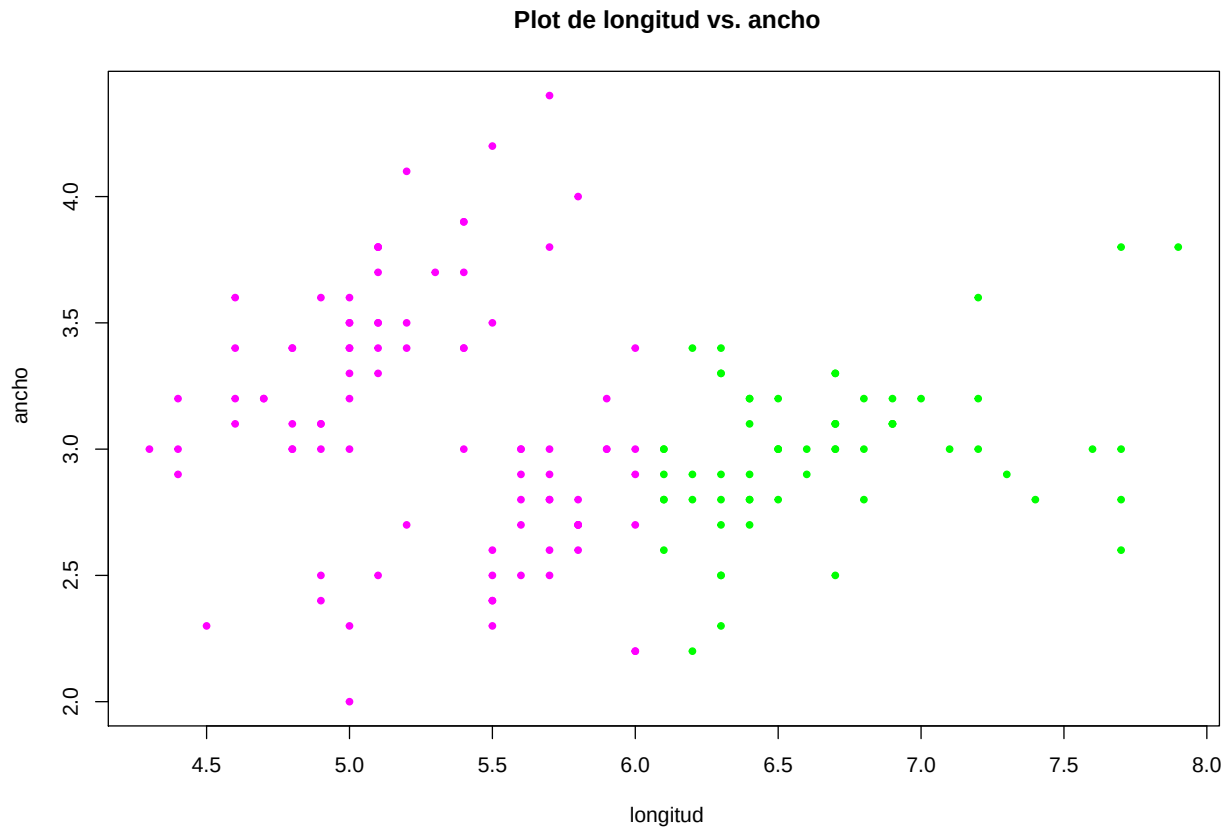

Gráficos para pares de variables

Ahora personalizando el gráfico

```
par(bg="lightgray",mar=c(4,2,3.5, 4))
#c(bottom, left, top, right)   defalut es c(5, 4, 4, 2) + 0.1.
plot(Sepal.Length,Sepal.Width,type="n",xlim=c(4,8),
     ylim=c(1,6),xlab="", ylab="",xaxt="n", yaxt="n")
#solo graficamos la caja
points(Sepal.Length,Sepal.Width,pch=20,col="magenta")

#solo graficamos los puntos con el simbolo deseado
#Ahora nos encargamos de los ejes
axis(1,c(4,6,8),cex=2)
mtext("Sepal.Length",side=1,cex=0.8,line=3)
axis(4,cex=0.8,col="blue",labels=FALSE)
mtext(c(1,3,5),side=4,at=c(1,3,5),col="blue",line=0.3)
mtext("Sepal.Width",side=4,cex=0.8,line=2.5,col="blue")
#titulo
title("Diagrama Personalizado de Sepal.Length
      vs. Sepal.Width",cex.main=0.8)
```

Gráficos para pares de variables

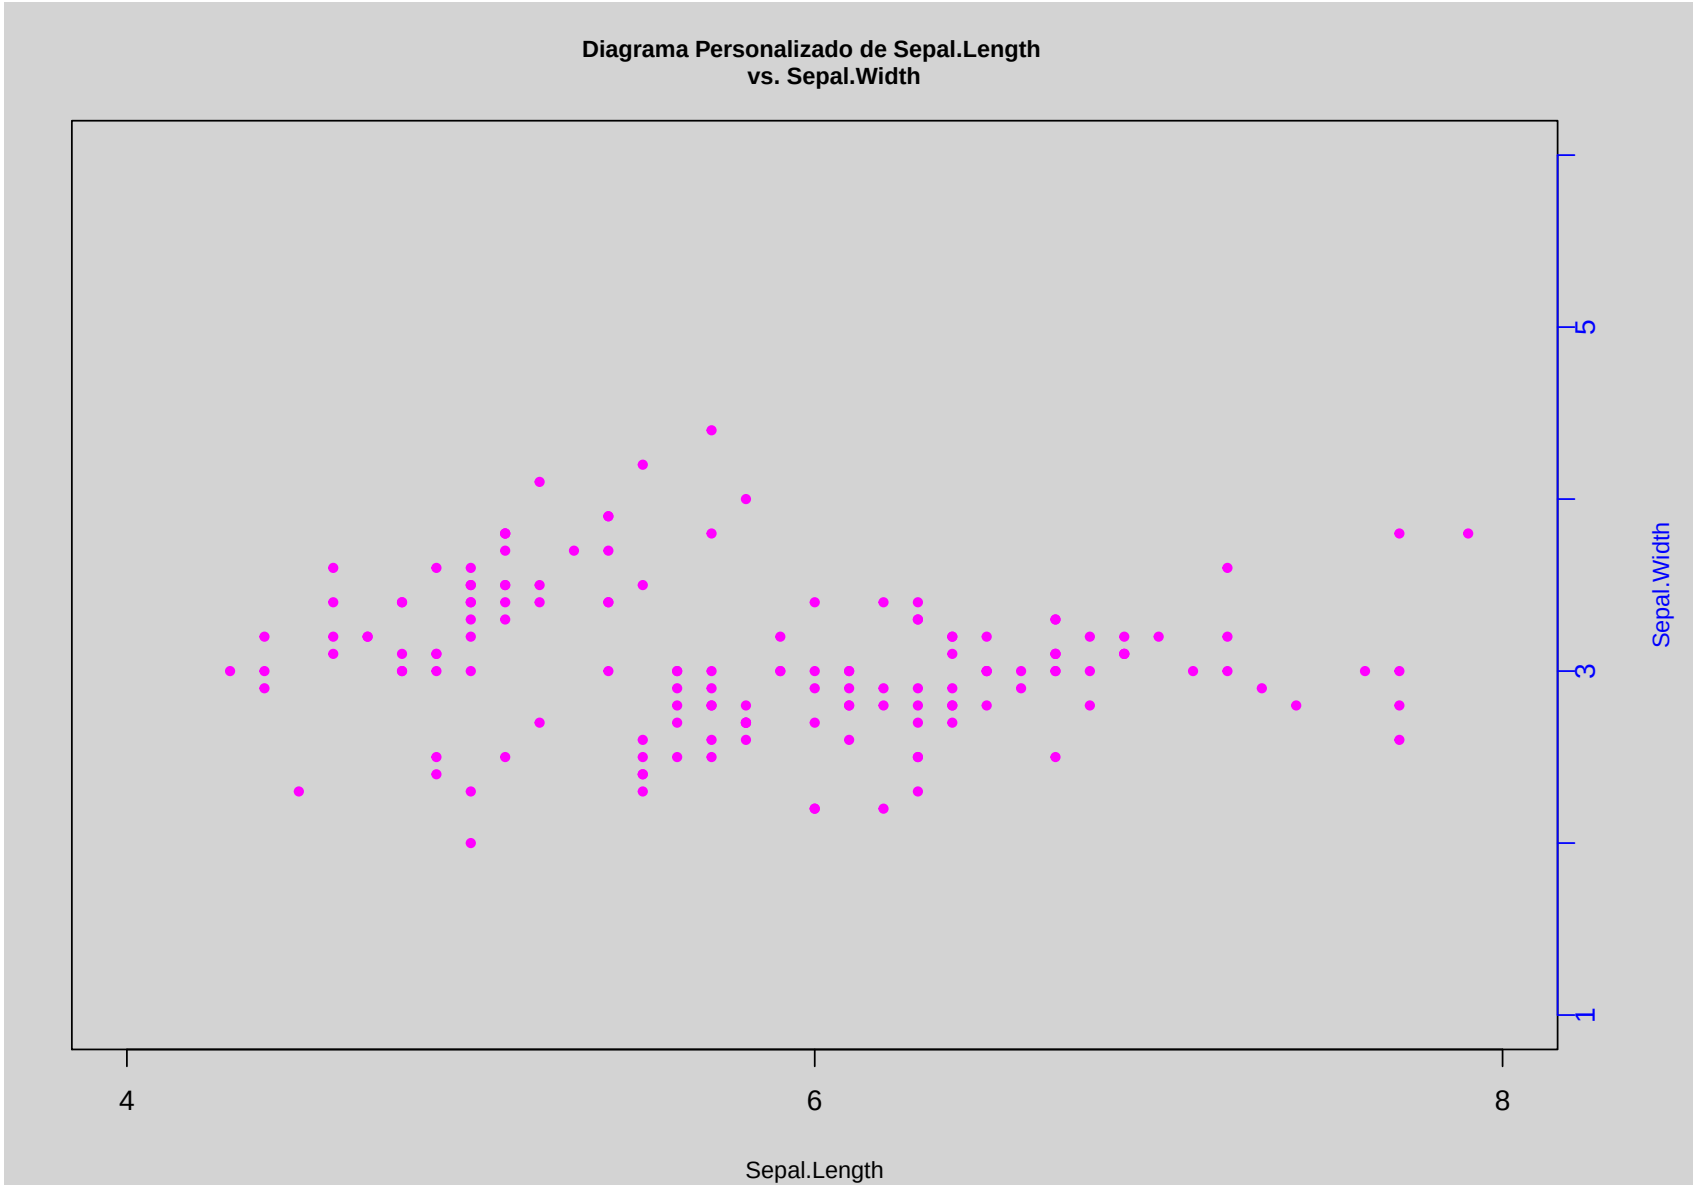

Gráficos para pares de variables

Diagrama de dispersión para todas las variables de SUB.

```
pairs(SUB,col="magenta")
```

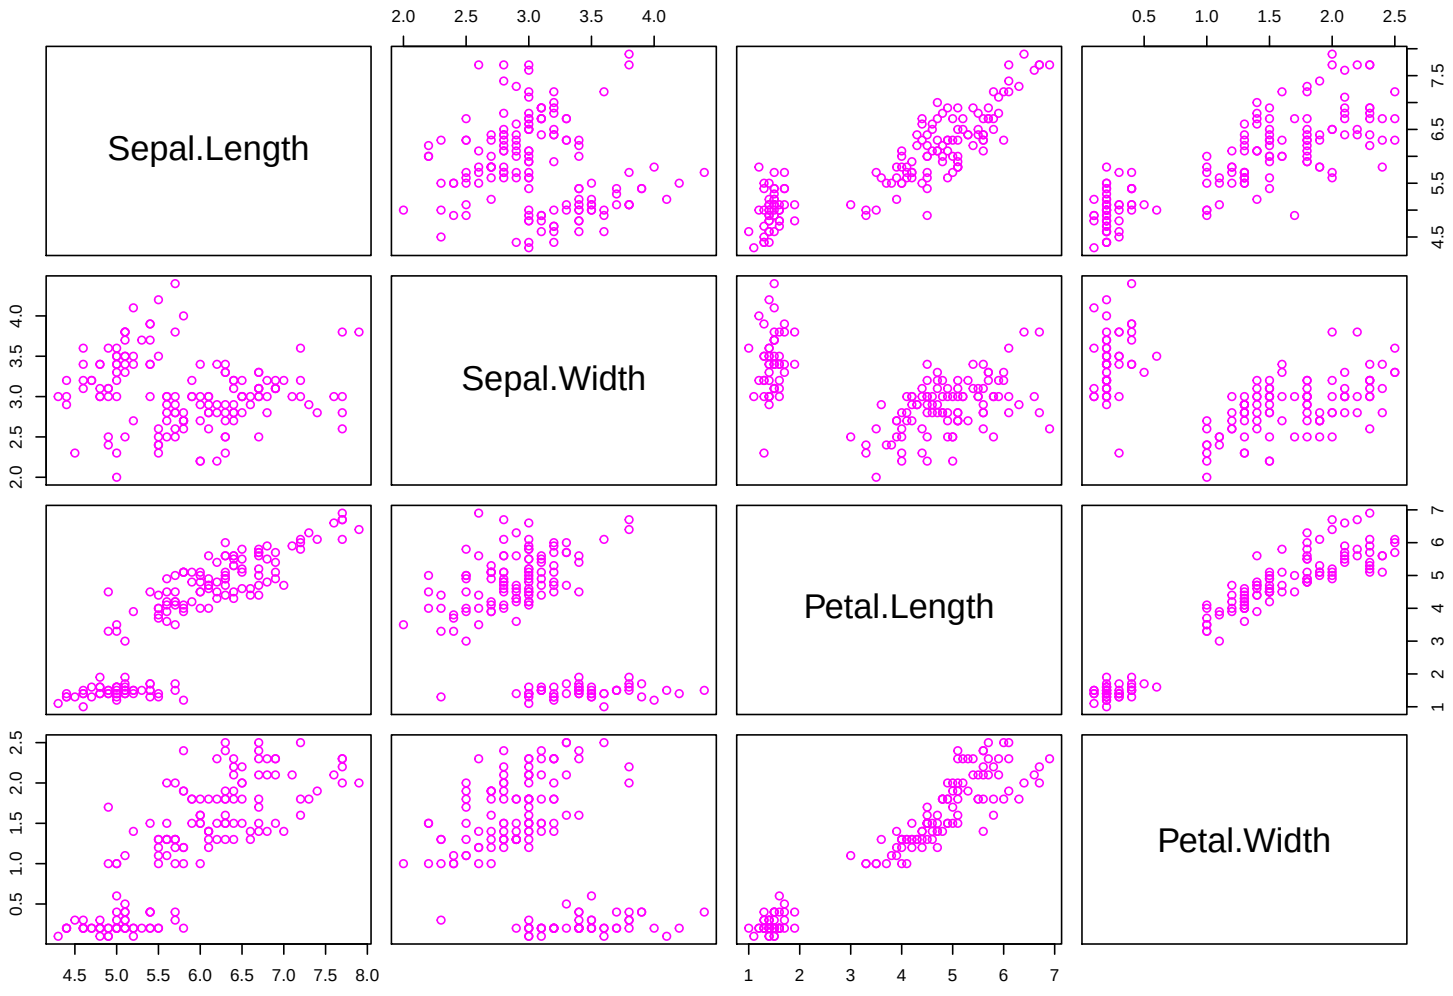

LIBRERIA GGPLOT

Existen dos motores gráficos en R.

- librería básica de R: utiliza funciones de alto nivel que invocan a funciones de bajo nivel. Ejemplo plot, hist, barplot, boxplot, etc
- motor gráfico alternativo: ej. lattice, ggplot2. Tiene una gramática. Es muy flexible. Es posible crear gráficos visualmente atractivos. Los datos tienen que estar siempre en dataframes

Instalar paquete *install.packages("ggplot2")*

Cargar paquete

```
library(ggplot2)
```

```
## Warning: package 'ggplot2' was built under R version 4.0.3
```

LIBRERIA GGPLOT

Los componentes de ggplot2

- data: Datos para graficar
- aesthetic mapping: Características estéticas
- geom: Objetos geométricos (puntos, líneas, polígonos, áreas.)
- stat: Transformaciones estadísticas
- scale: Escalas
- coord: El sistema de coordenadas
- faceting: Condicionamiento

GGPLOT: Para pares de variables

```
ggplot(data=iris, aes(x=Sepal.Length,y=Sepal.Width ))+
  geom_point()
```

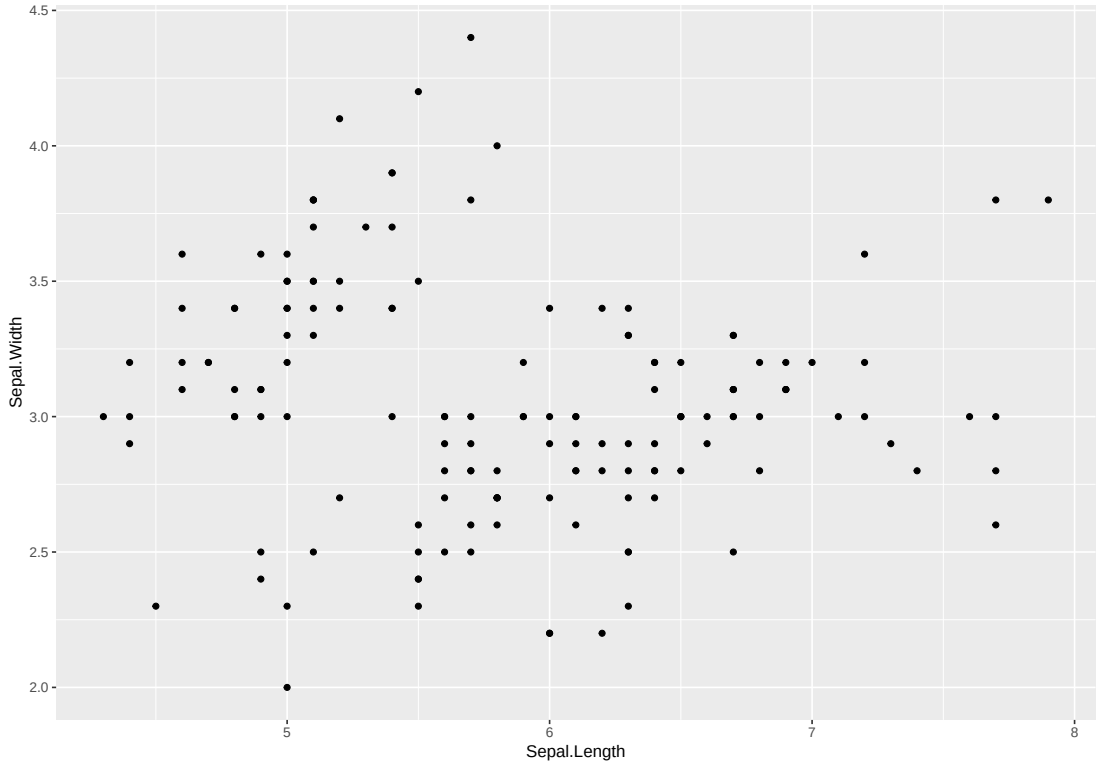

GGPLOT: agregamos labels en los ejes

```
ggplot(data=iris, aes(x=Sepal.Length,y=Sepal.Width ))+
  geom_point()+xlab("Longitud")+ylab("Ancho")
```

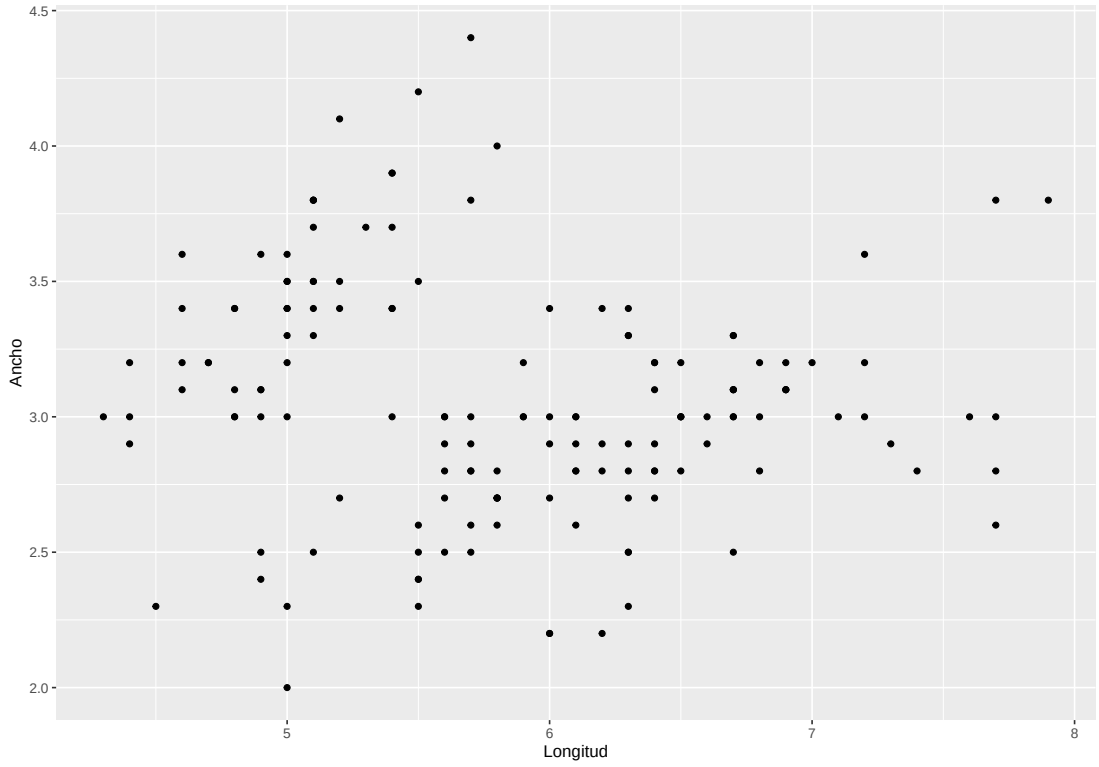

GGPLOT: ¿y si no ponemos geom_point?

```
ggplot(data=iris, aes(x=Sepal.Length,y=Sepal.Width ))
```

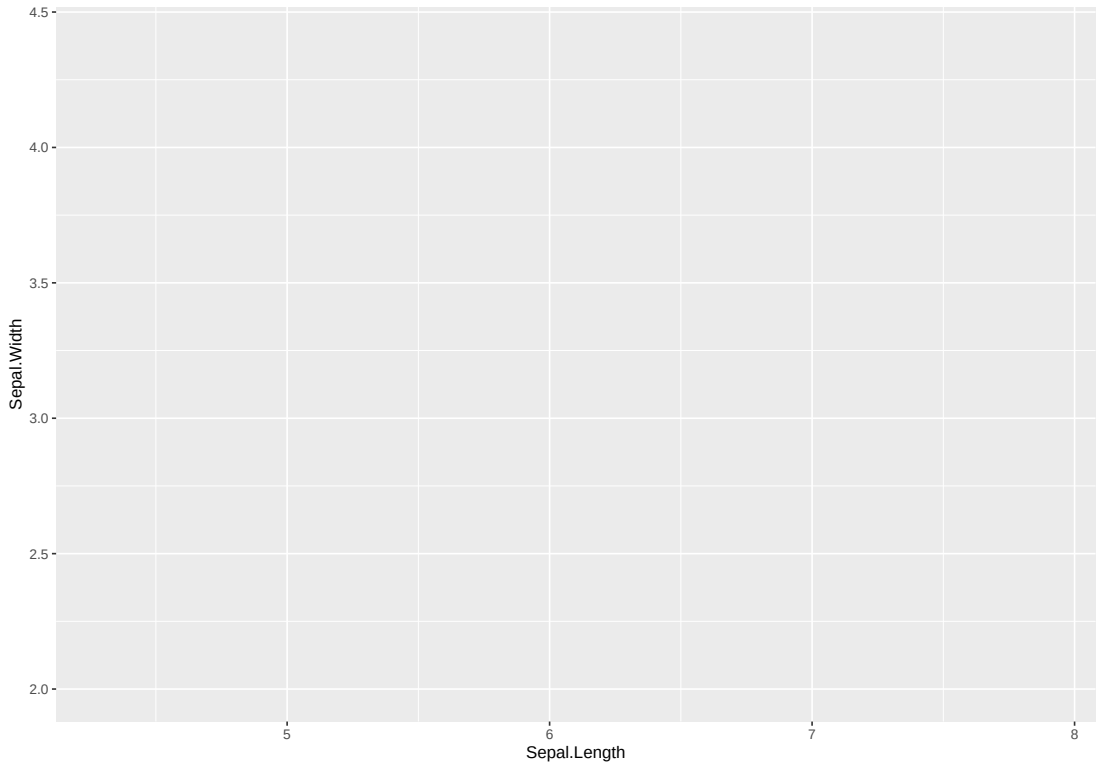

GGPLOT: geom.line()

```
ggplot(data=iris, aes(x=Sepal.Length,y=Sepal.Width ))+
geom_line()
```

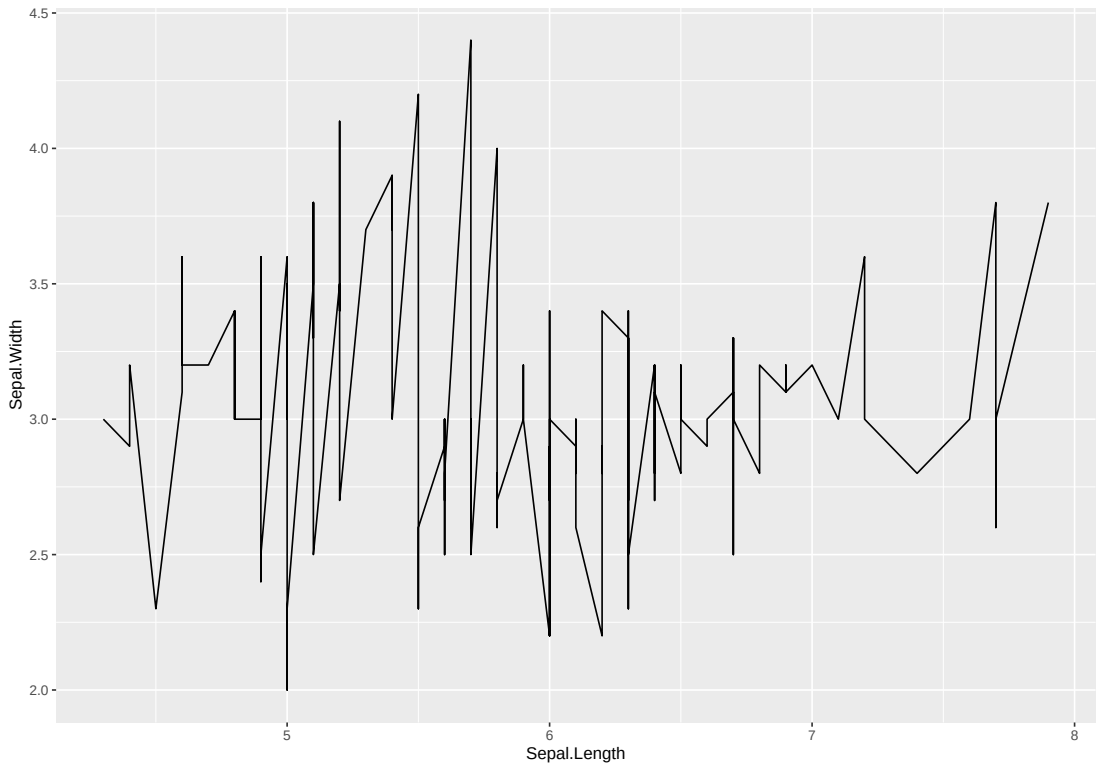


```
#No resulta útil en este ejemplo, solo para ilustrar
```

GGPLOT: Existen otras geoms

```
ggplot(data=iris, aes(x="",y=Sepal.Length))+
  geom_boxplot()
```

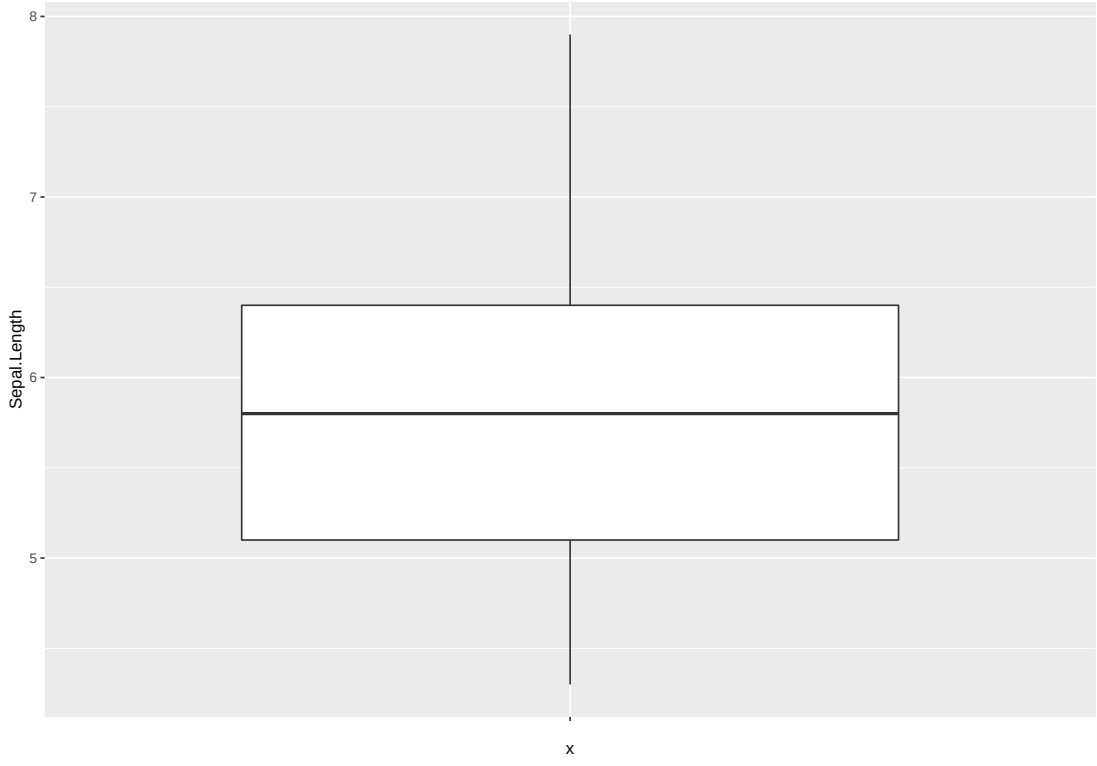

GGPLOT: Existen otras geoms

```
ggplot(data=iris, aes(x=Sepal.Length,y=""))+
  geom_boxplot()
```

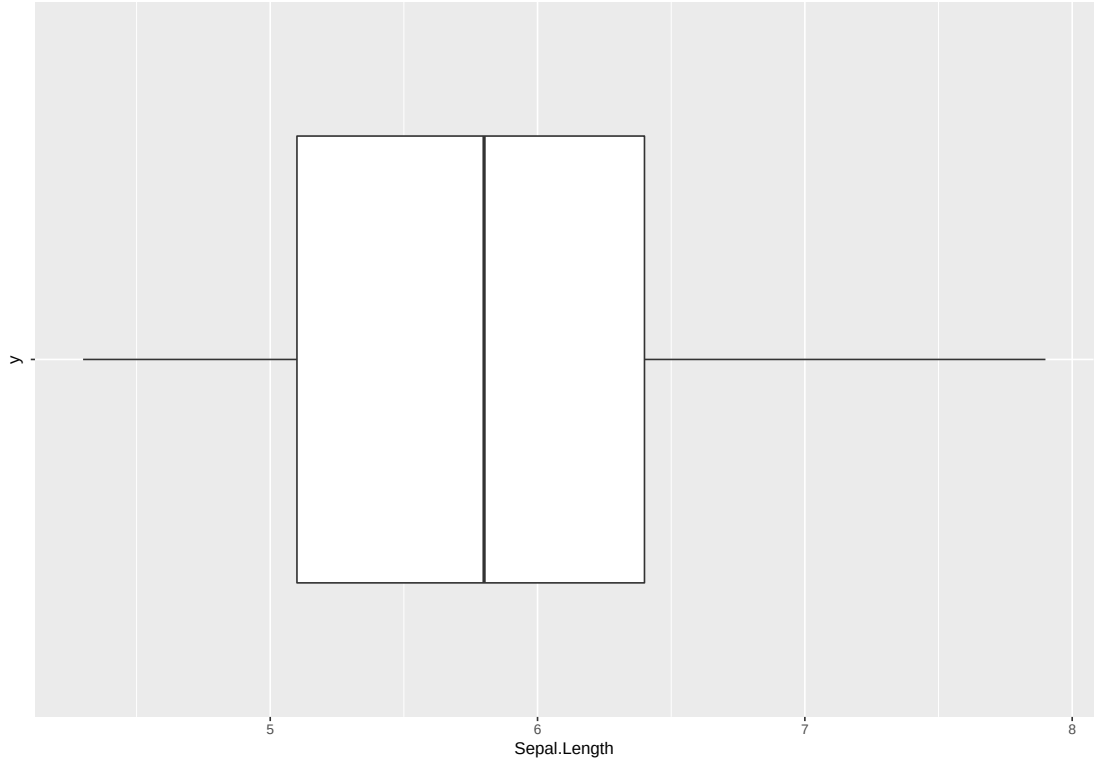

GGPLOT: Boxplot

```
ggplot(data=iris, aes(x=Species,y=Sepal.Length))+
  geom_boxplot( col="red")+
  ylab("Longitud del Sepal")+xlab("Tipo de Iris")+
  ggtitle("Boxplot por tipo de Iris")
```

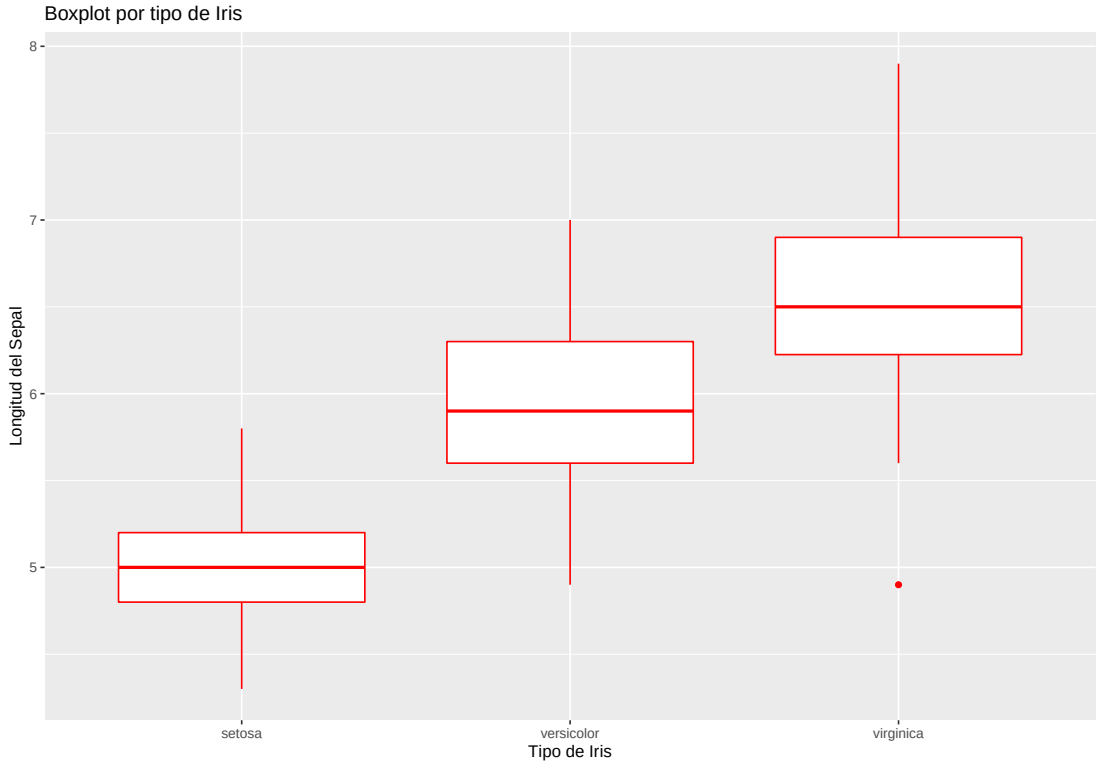

GGPLOT: Boxplot

O bien

```
ggplot(data=iris, aes(x="",y=Sepal.Length))+
  geom_boxplot( col="red")+facet_grid(. ~ Species)
```

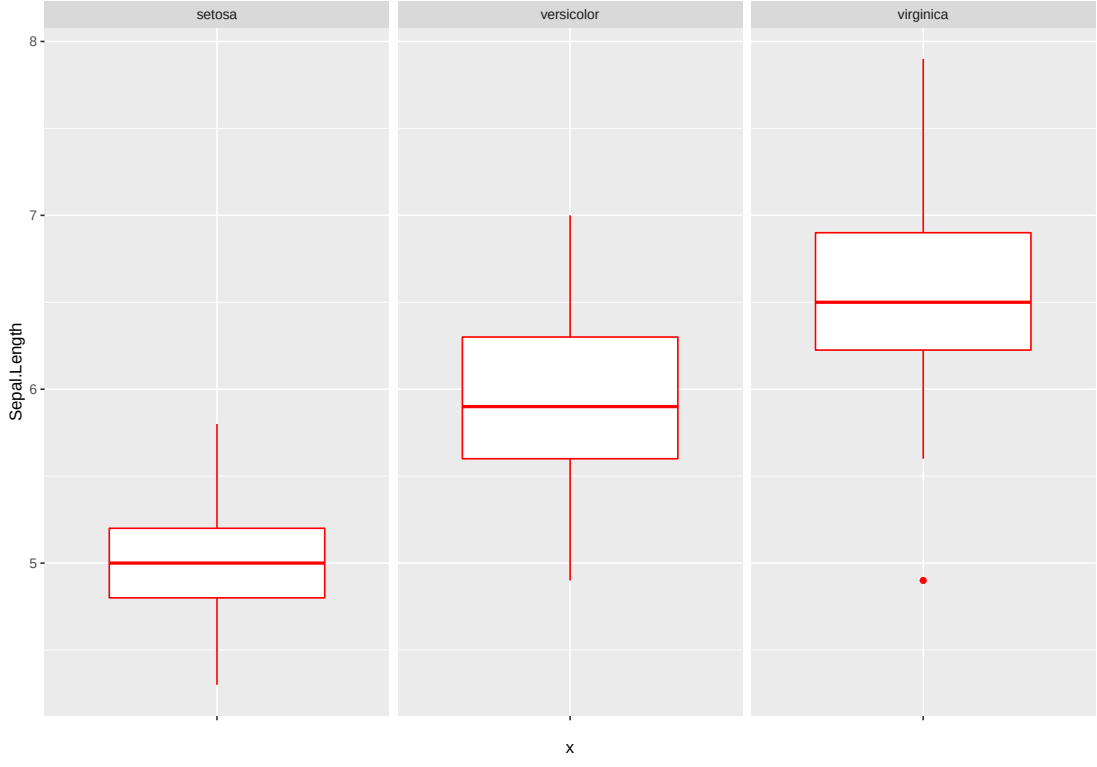

GGPLOT: Histograma

```
ggplot(data = iris,aes(x=Sepal.Length))+geom_histogram()
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwi
```

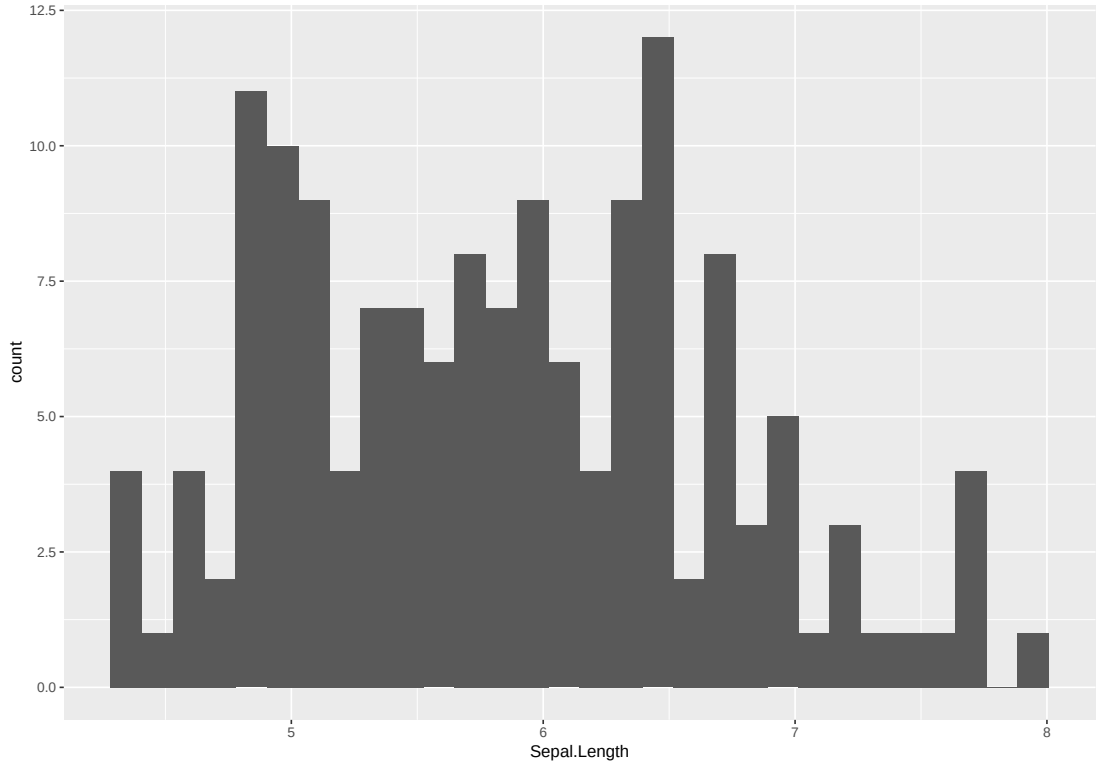

GGPLOT: Histograma

```
ggplot(data = iris,aes(x=Sepal.Length))+
  geom_histogram(bins = 15,  col="red")
```

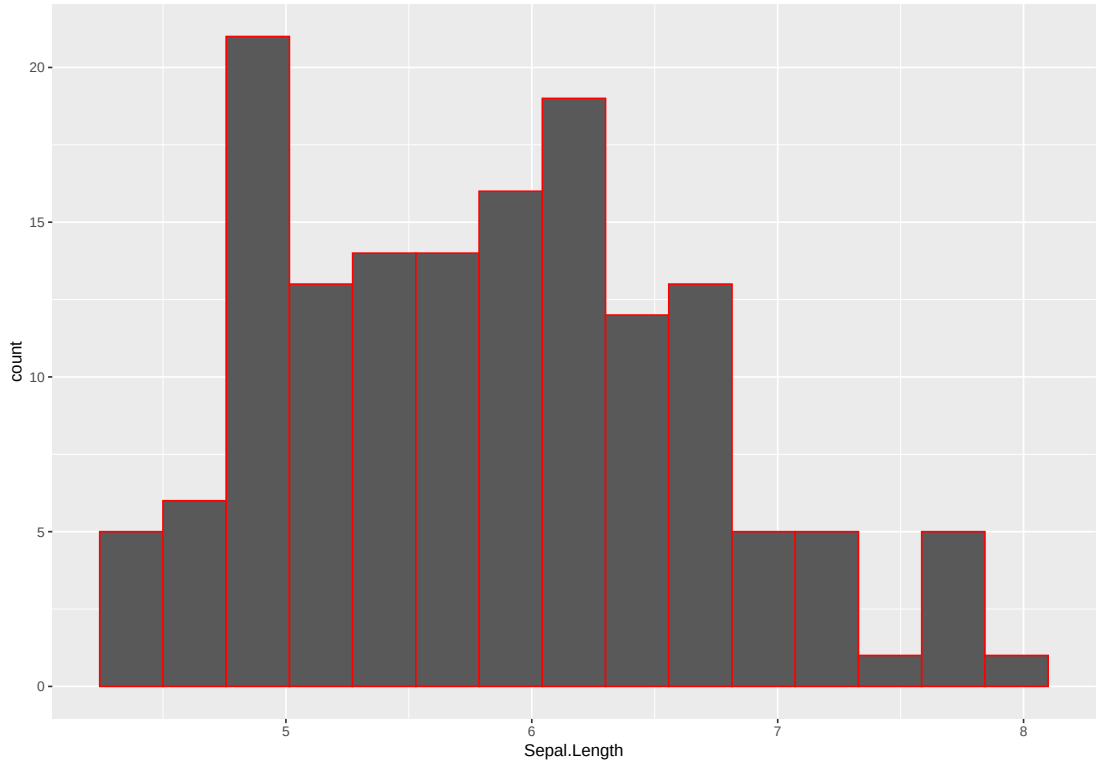

GGPLOT: Histograma

Para generar el histograma con la medición de la densidad

```
ggplot(data=iris, aes(x=iris$Sepal.Length))+
  geom_histogram(aes(y=..density..),breaks =
c(4.5,5,6.3,6.8,8) , col="red")+
  xlab("Rango de Valores")+ggtitle("Histograma")
```

```
## Warning: Use of `iris$Sepal.Length` is discouraged. Use `Sepal.Lengt
```

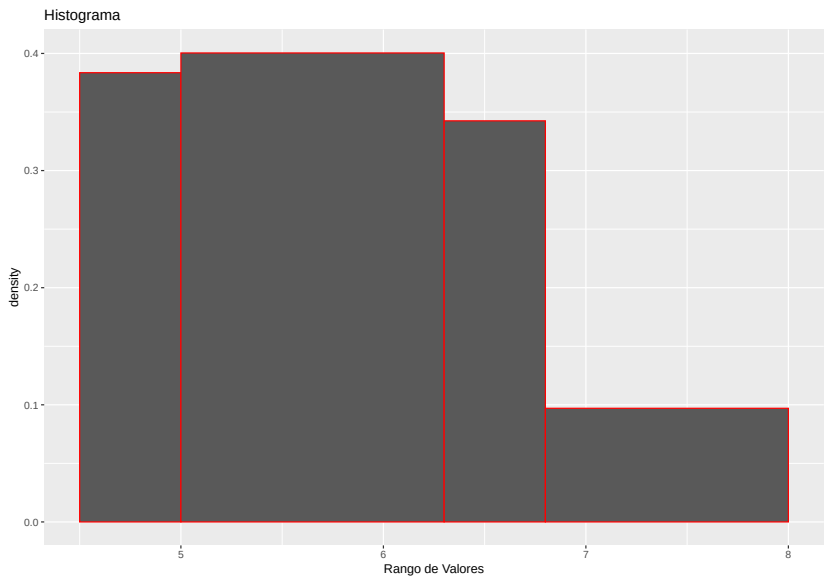

GGPLOT: Histograma

Varios histogramas según condición

```
ggplot(data=iris, aes(x=Sepal.Length))+
  geom_histogram(binwidth=1,color="black",aes(
    y=..density..,fill=..count..))+
  facet_grid(. ~ Species)
```

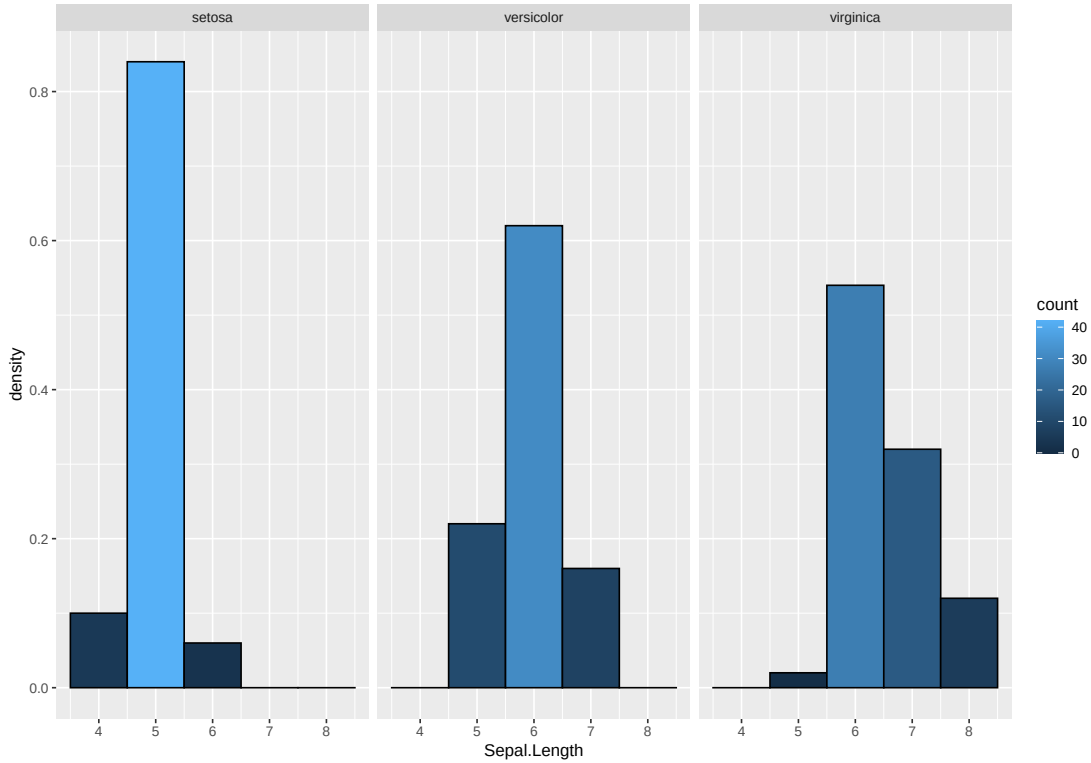

GGPLOT: Histograma

Histograma con la curva de densidad normal superpuesta

```
media.es<-mean(Sepal.Length)
desvio.es<-sd(Sepal.Length)

gg<-ggplot(data=iris, aes(x=Sepal.Length))
gg<-gg+geom_histogram(binwidth=1,color="black",
                      aes(y=..density..,fill=..count..))
gg<-gg+scale_fill_gradient("Count", low="#DCDCDC",
                           high="#7C7C7C")
```

ahora superpongo

```
gg<-gg + stat_function(fun = dnorm,color="red",
                       args=list(mean=media.es, sd=desvio.es))
gg+xlab("Rango de Valores")+ggtitle("Histograma")
```

GGPLOT: Histograma

Histograma con la curva de densidad normal superpuesta

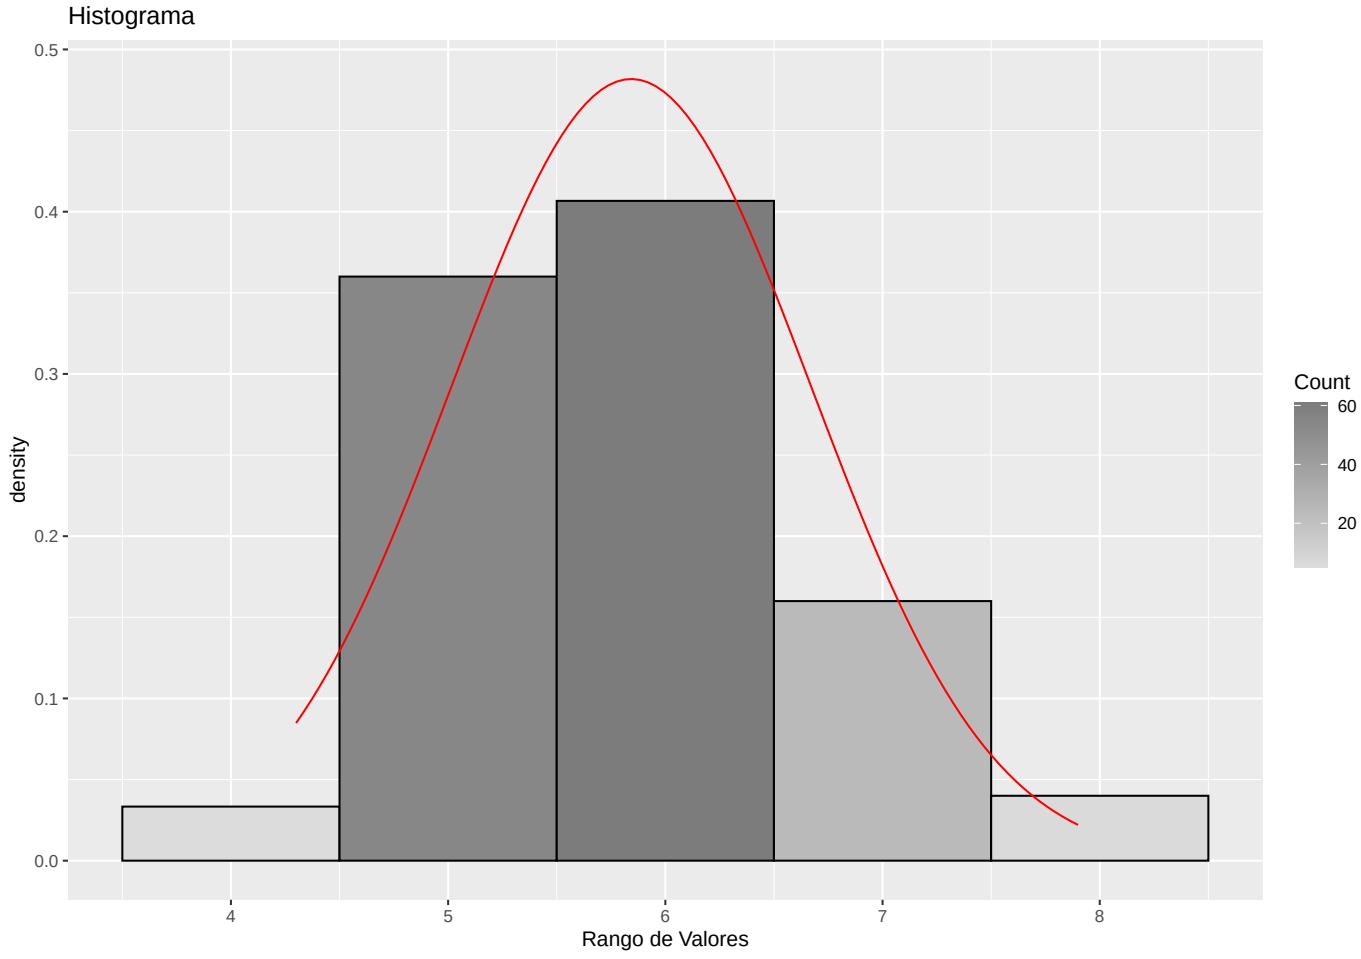

GGPLOT: Gráficos de barra para variables categóricas

```
ggplot(data=iris, aes(x=Species))+geom_bar(width=0.25)
```

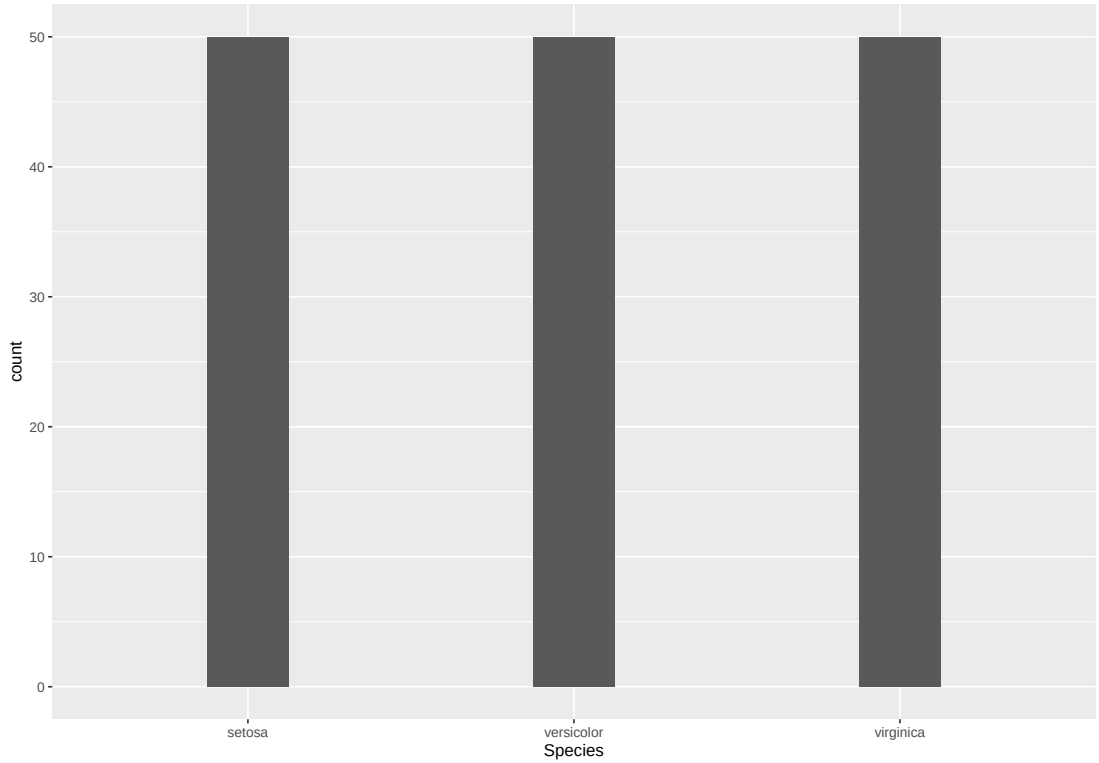

GGPLOT: Gráficos de barra para variables categóricas

```
ggplot(data=iris, aes(x=Species))+geom_bar(aes(fill=Species),
       width=0.5)
```

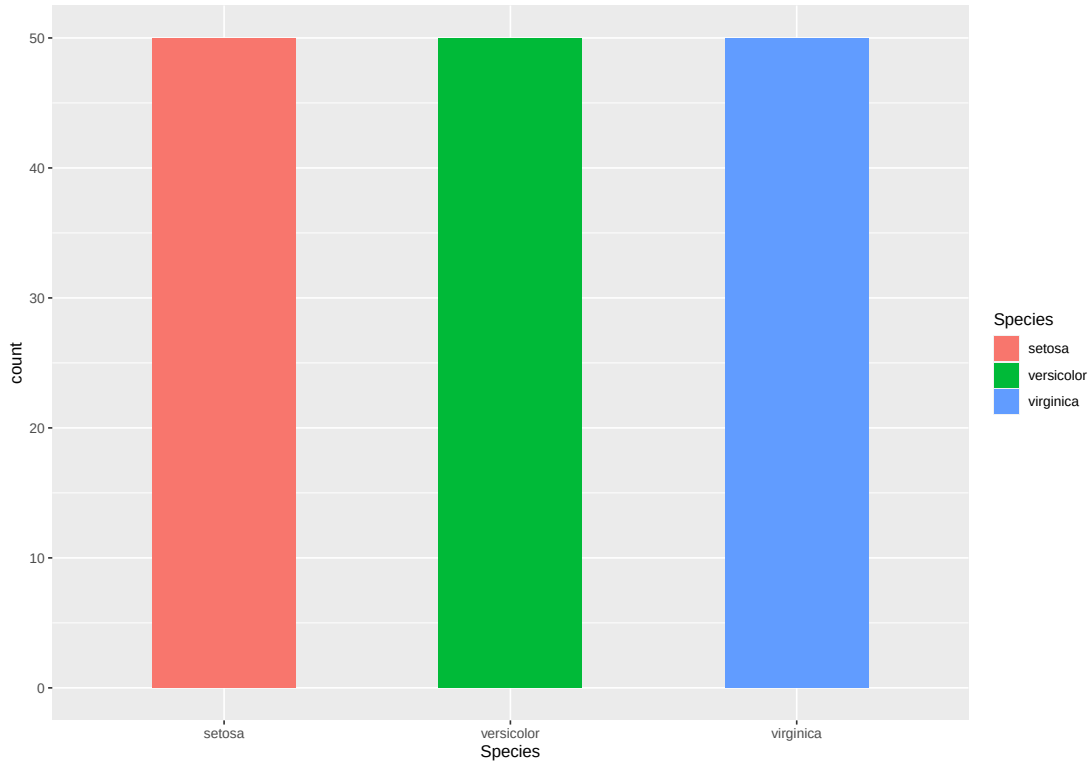

GGPLOT: Gráficos de torta para variables categóricas

```
ggplot(data=iris, aes(x=Species,fill=Species))+
  geom_bar(width=1)+coord_polar()
```

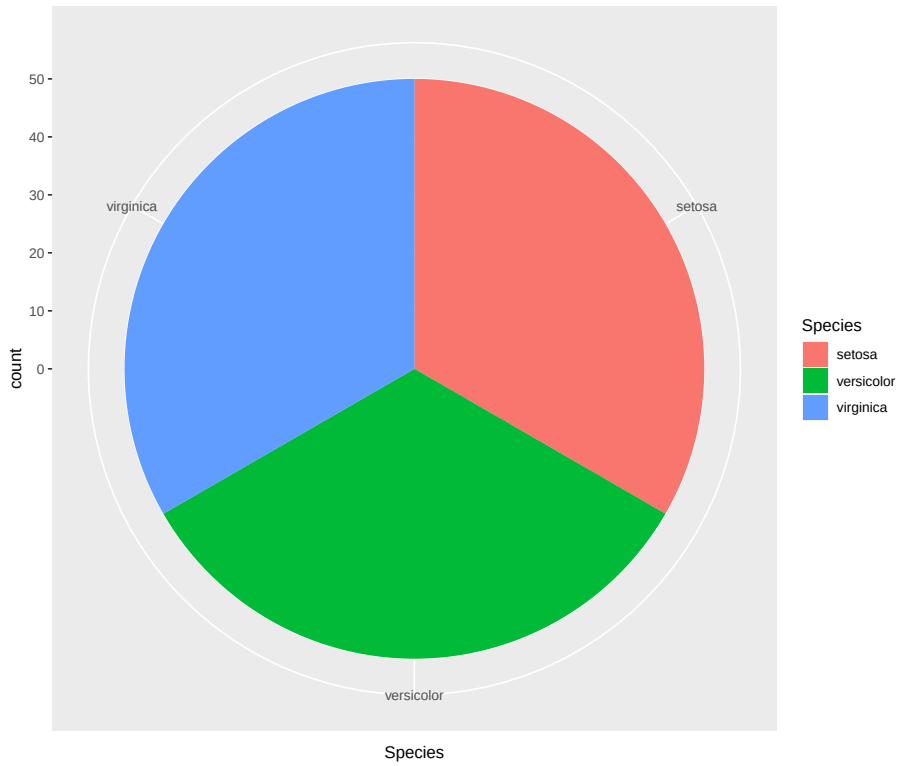

Inventemos una variable

En nuestos datos tenemos solo una variable categórica. Supongamos que tenemos una variable más que es

```
#invento que hay flores que fuman tiene un 1 y 0 si no fuman
fuma<-c(rbinom(50,1,0.3),rbinom(50,1,0.5),rbinom(50,1,0.1))
class(fuma)
```

```
## [1] "integer"
```

```
fuma<-as.factor(fuma)
counts<-table(fuma,Species)
counts
```

```
##     Species
## fuma setosa versicolor virginica
##    0     33         18        45
##    1     17         32         5
```

GGPLOT: más de una variables categóricas

```
iris2<-data.frame(cbind(iris,fuma))
ggplot(data=iris2, aes(x=Species))+geom_bar(aes(fill=Species),
       width=0.5)+ facet_grid(. ~ fuma)
```

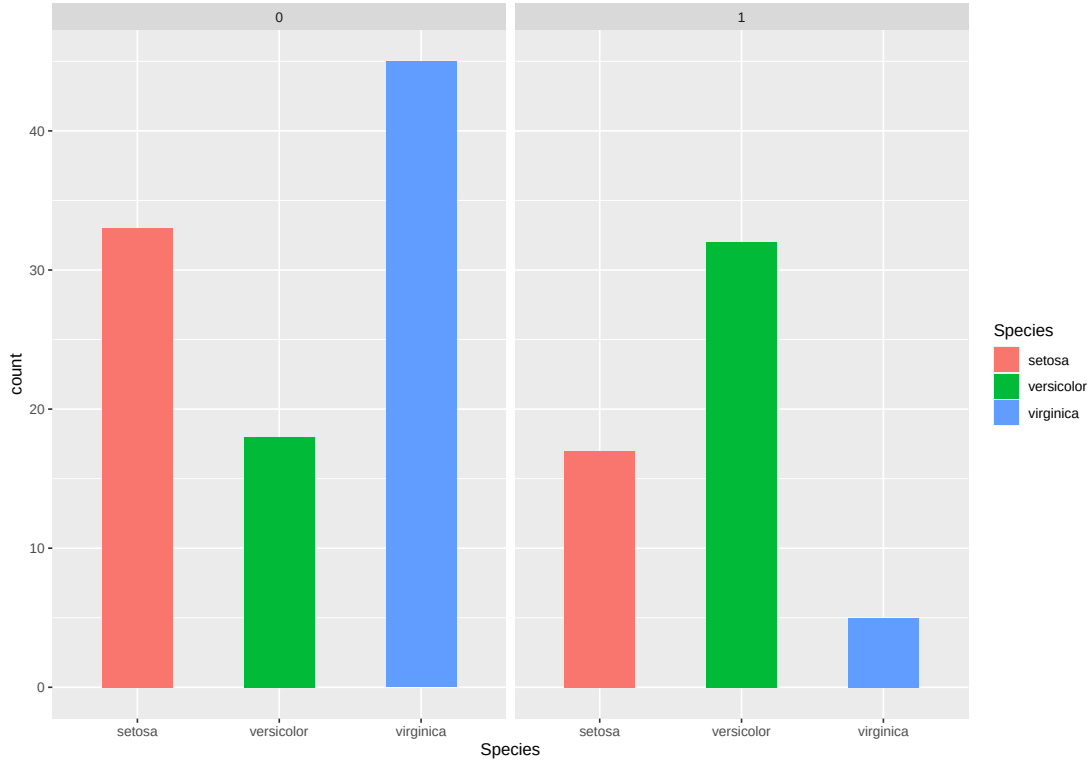

GGPLOT: Guardado

Para guardar simplemente

```
ggsave("mi_grafico.png")
```

```
## Saving 10 x 7 in image
```

Una más y ....

```
library(ggExtra)
```

```
## Warning: package 'ggExtra' was built under R version 4.0.3
```

```
library(gridExtra)
library(viridis)
```

```
## Loading required package: viridisLite
```

```
# classic plot :
p1 <- ggplot(iris, aes(x=Sepal.Length, y=Sepal.Width, color=Species, size=Sepal.Length)) +
      geom_point(alpha=0.5) +scale_color_viridis(discrete=TRUE, guide=FALSE)+
      theme(legend.position="none")

# Tamaño relativo de graficos (principal 5x mas grande que los marginales)
p2 <- ggMarginal(p1, type="histogram", fill = "#20A387FF", size=10)
```

Gráfico Final

```
grid.arrange(p1, p2, ncol=2,nrow=1)
```

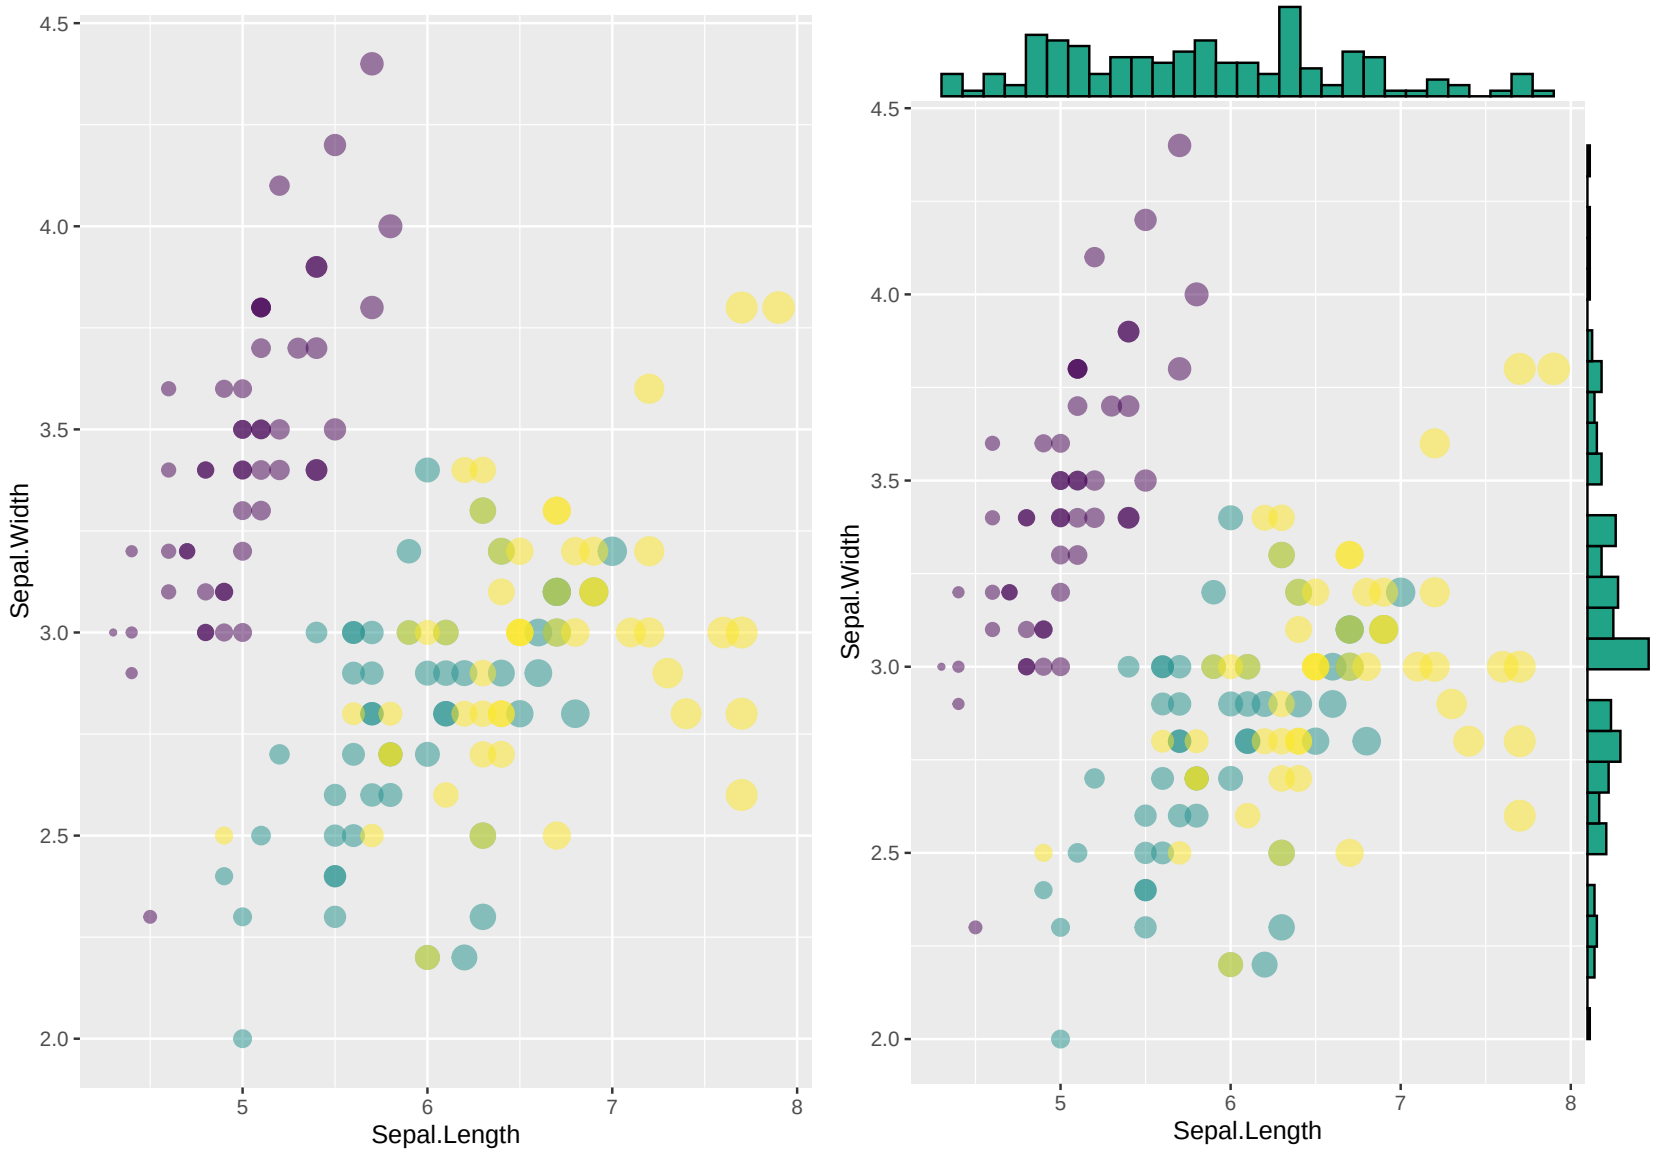

Recomendaciones

- Visiten: (https://www.r-graph-gallery.com/index.html)